Actividad Módulo 25: Introducción a Machine Learning Parte 1

1. Exploración básica de EDA utilizando tail, sample, shape, info
2. Validar si es que existen nulos o información vacía en el dataset, tipo de datos, describe, nunique
3. Correlación y heatmap y visualización de la distribución utilizando sns.distplot
4. Eliminación de variables con alta correlación y/o que no sean necesarias
5. Reportes por grupos (cuántos registros):
    - Estado civil
    - Educación
    - Trabajo
6. Análisis univariado y bivariado basado en la predicción y/n
7. Dividir dataset en training y testing (70%-30%)

In [ ]:
```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

In [ ]:
```
# 1. Importar el dataset, tail, sample, shape, info
df = pd.read_csv('bank-additional-full.csv', sep=';')
df.tail()
```

Out[ ]:

	age	job	marital	education	default	housing	loan	contact	month	day_of_week	...	campaign	pdays	previous
41183	73	retired	married	professional.course	no	yes	no	cellular	nov	fri	...	1	999	0
41184	46	blue-collar	married	professional.course	no	no	no	cellular	nov	fri	...	1	999	0
41185	56	retired	married	university.degree	no	yes	no	cellular	nov	fri	...	2	999	0
41186	44	technician	married	professional.course	no	no	no	cellular	nov	fri	...	1	999	0
41187	74	retired	married	professional.course	no	yes	no	cellular	nov	fri	...	3	999	1

5 rows × 21 columns

In [ ]:
```
df.sample(10)
```

Out[ ]:

	age	job	marital	education	default	housing	loan	contact	month	day_of_week	...	campaign	pdays	previou
18991	45	services	married	high.school	unknown	yes	no	cellular	aug	mon	...	2	999	
28394	51	services	married	high.school	unknown	no	no	cellular	apr	thu	...	3	999	
8030	55	retired	divorced	basic.6y	unknown	no	no	telephone	jun	mon	...	2	999	
27119	35	admin.	divorced	university.degree	no	no	no	cellular	nov	fri	...	6	999	
2371	36	admin.	married	high.school	no	no	yes	telephone	may	tue	...	1	999	
32640	35	blue-collar	married	unknown	no	yes	no	cellular	may	mon	...	8	10	
2055	35	admin.	married	university.degree	no	yes	no	telephone	may	mon	...	3	999	
222	36	services	single	basic.6y	unknown	yes	no	telephone	may	mon	...	1	999	
2217	54	technician	married	university.degree	unknown	no	yes	telephone	may	mon	...	7	999	
25360	30	services	married	high.school	no	yes	no	cellular	nov	tue	...	1	999	

10 rows × 21 columns

In [ ]:
```
df.shape
```

Out[ ]:
```
(41188, 21)
```

In [ ]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 41188 entries, 0 to 41187
Data columns (total 21 columns):
 #   Column          Non-Null Count  Dtype  
---  ------          --------------  -----  
 0   age             41188 non-null  int64  
 1   job             41188 non-null  object 
 2   marital         41188 non-null  object 
 3   education       41188 non-null  object 
 4   default         41188 non-null  object 
 5   housing         41188 non-null  object 
 6   loan            41188 non-null  object 
 7   contact         41188 non-null  object 
 8   month           41188 non-null  object 
 9   day_of_week     41188 non-null  object 
 10  duration        41188 non-null  int64  
 11  campaign        41188 non-null  int64  
 12  pdays           41188 non-null  int64  
 13  previous        41188 non-null  int64  
 14  poutcome        41188 non-null  object 
 15  emp.var.rate    41188 non-null  float64
 16  cons.price.idx  41188 non-null  float64
 17  cons.conf.idx   41188 non-null  float64
 18  euribor3m       41188 non-null  float64
 19  nr.employed     41188 non-null  float64
 20  y               41188 non-null  object 
dtypes: float64(5), int64(5), object(11)
memory usage: 6.6+ MB
```

In [ ]:
```
# 2.1 Validar si existen valores nulos o información faltante

df.isnull().sum().sum()     # NO EXITEN VALORES NULOS
```

Out[ ]:
```
0
```

In [ ]:
```
# 2.2 Tipo de datos arriba en df.info()
# 2.3 Describe
df.describe().T
```

Out[ ]:

	count	mean	std	min	25%	50%	75%	max
age	41188.0	40.024060	10.421250	17.000	32.000	38.000	47.000	98.000
duration	41188.0	258.285010	259.279249	0.000	102.000	180.000	319.000	4918.000
campaign	41188.0	2.567593	2.770014	1.000	1.000	2.000	3.000	56.000
pdays	41188.0	962.475454	186.910907	0.000	999.000	999.000	999.000	999.000
previous	41188.0	0.172963	0.494901	0.000	0.000	0.000	0.000	7.000
emp.var.rate	41188.0	0.081886	1.570960	-3.400	-1.800	1.100	1.400	1.400
cons.price.idx	41188.0	93.575664	0.578840	92.201	93.075	93.749	93.994	94.767
cons.conf.idx	41188.0	-40.502600	4.628198	-50.800	-42.700	-41.800	-36.400	-26.900
euribor3m	41188.0	3.621291	1.734447	0.634	1.344	4.857	4.961	5.045
nr.employed	41188.0	5167.035911	72.251528	4963.600	5099.100	5191.000	5228.100	5228.100

In [ ]:

```
# Número de valores únicos por columna
for column in df.columns:
    print(f'Hay {df[column].nunique()} valores únicos para la columna {column}')
```

```
Hay 78 valores únicos para la columna age
Hay 12 valores únicos para la columna job
Hay 4 valores únicos para la columna marital
Hay 8 valores únicos para la columna education
Hay 3 valores únicos para la columna default
Hay 3 valores únicos para la columna housing
Hay 3 valores únicos para la columna loan
Hay 2 valores únicos para la columna contact
Hay 10 valores únicos para la columna month
Hay 5 valores únicos para la columna day_of_week
Hay 1544 valores únicos para la columna duration
Hay 42 valores únicos para la columna campaign
Hay 27 valores únicos para la columna pdays
Hay 8 valores únicos para la columna previous
Hay 3 valores únicos para la columna poutcome
Hay 10 valores únicos para la columna emp.var.rate
Hay 26 valores únicos para la columna cons.price.idx
Hay 26 valores únicos para la columna cons.conf.idx
Hay 316 valores únicos para la columna euribor3m
Hay 11 valores únicos para la columna nr.employed
Hay 2 valores únicos para la columna y
```

In [ ]:
```
# Correlación y heatmap
sns.heatmap(df.corr(numeric_only=True), cmap='Blues', annot=True, fmt='.2f')
```

Out[ ]:
```
<AxesSubplot: >
```

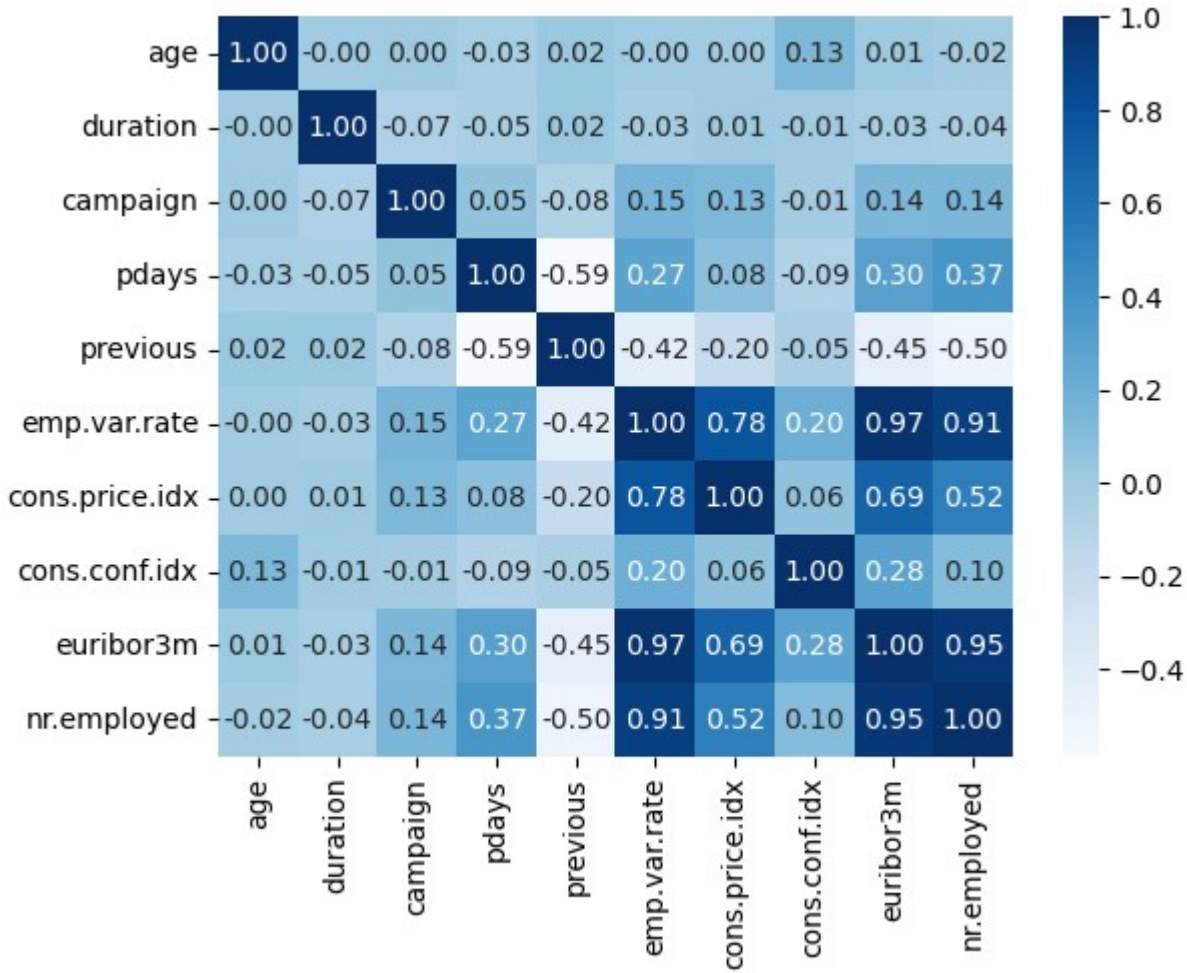

Insights:

- Existen varibles con alta correlación:
  - cons.price.idx - emp.var.rate
  - euribor3m - emp.var.rate
  - nr.employed - emp.var.rate
  - nr.employed - euribor3m

In [ ]:
```
# Visualización de las distribuciones con histogramas
fig, ax = plt.subplots(nrows=3, ncols=4, figsize=(18,16))

columns = ['age', 'duration', 'campaign', 'pdays', 'previous', 'emp.var.rate', 'cons.price.idx', 'cons.conf.idx', 'eu

for i, column in enumerate(columns):
    sns.histplot(data=df[column], ax=ax[i//4, i%4], kde=False)
```

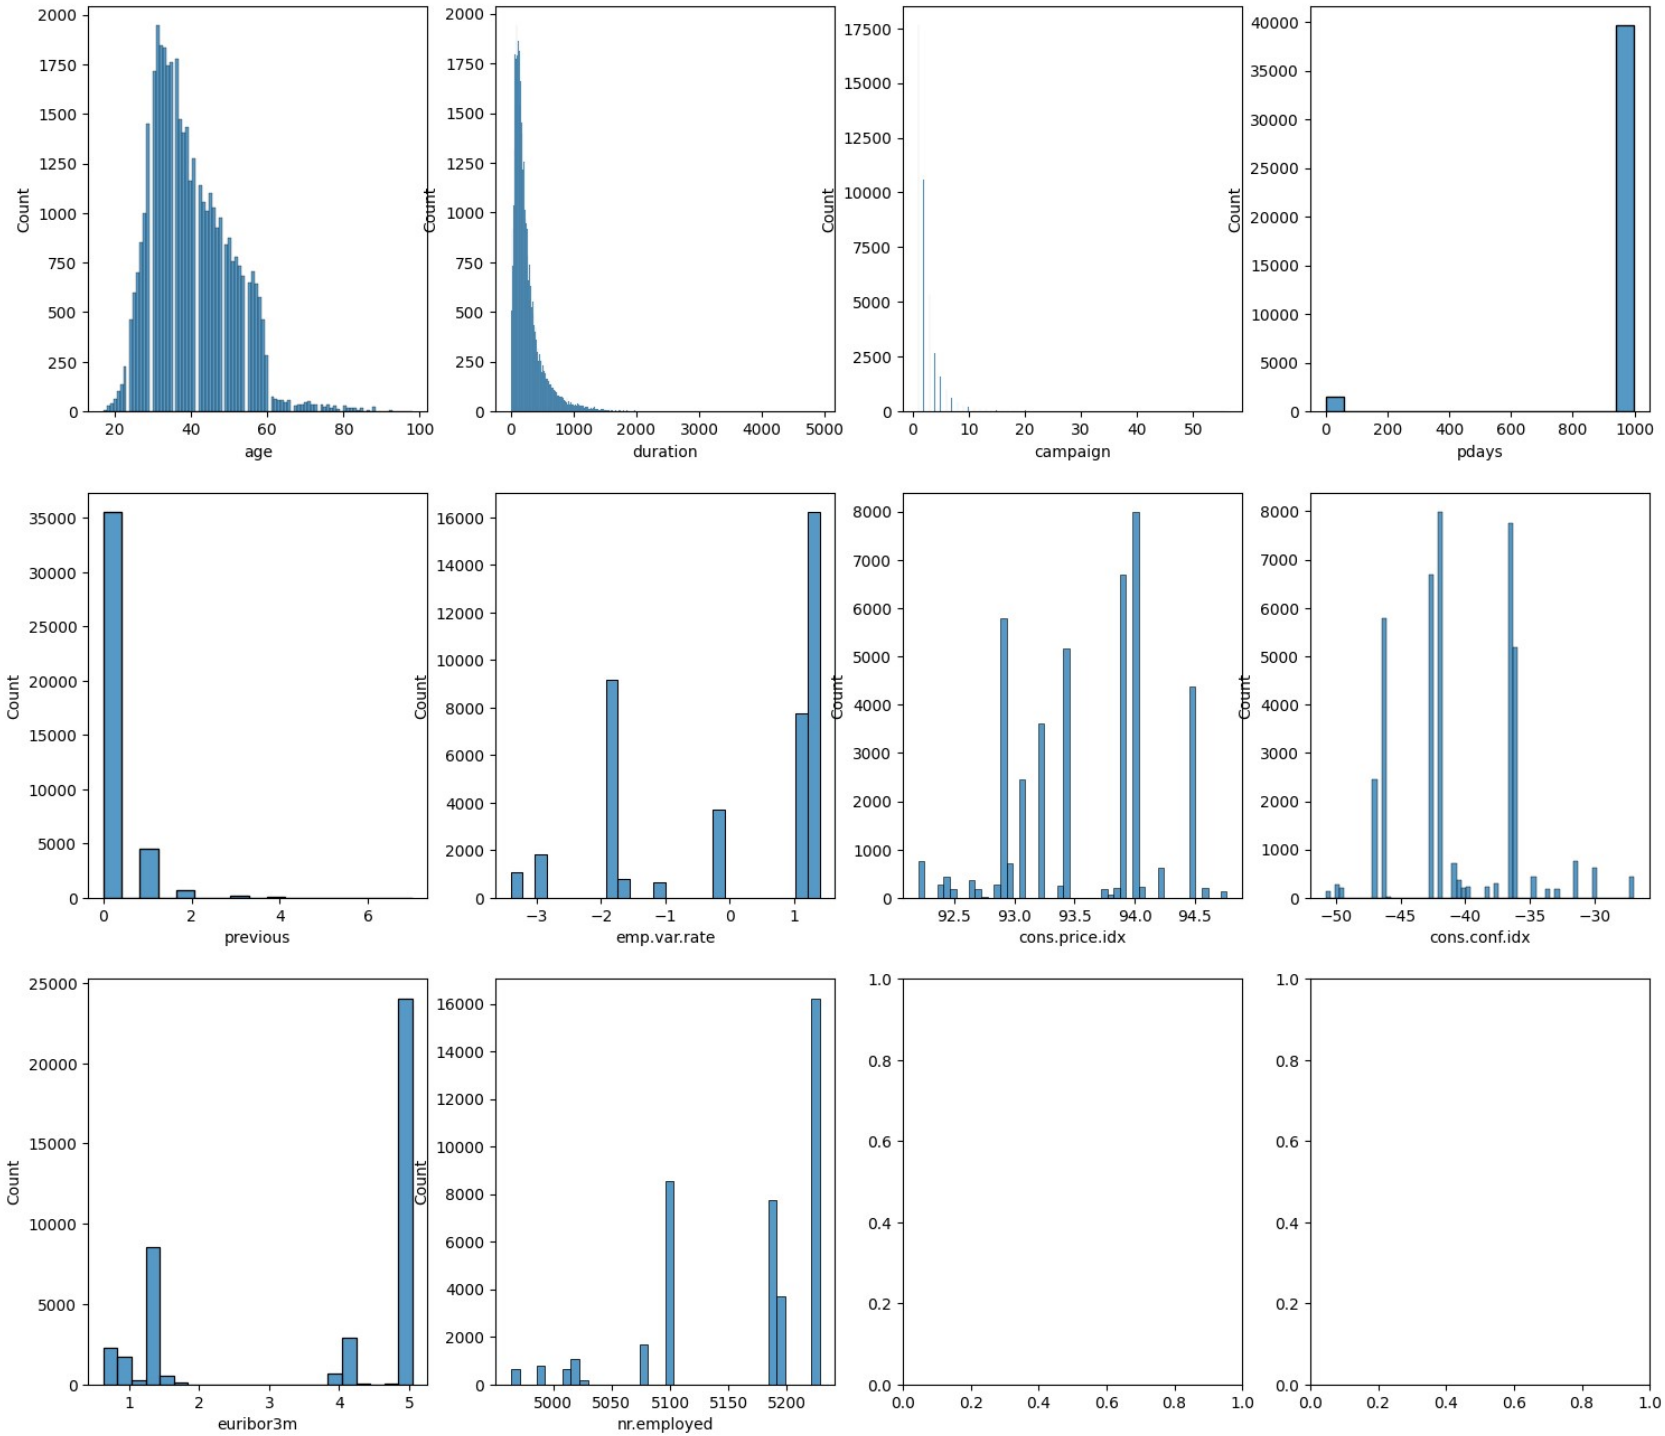
Count
age
duration
campaign
pdays
previous
emp.var.rate
cons.price.idx
cons.conf.idx
euribor3m
nr.employed

Insights:

- Se puede ver que la varialbe duration tiene un alto sesgo, pero existen valores muy lejos
- La gran mayoría de los clientes contactados en esta campaña no habían sido contactados para campañas pasadas
- Por lo mismo que muchos clientes nunca habían sido contactados en campañas anteriores, la mayoría de los clentes están en cero en la columna previous

In [ ]:
```
# Eliminación de variables con alta correlación y variables no necesarias
# Borraré todas las coluumnas con alta correlación y dejaré unicamente emp.var.rate para minimizar la cantidad de col
df.drop(columns=['cons.price.idx', 'euribor3m', 'nr.employed'], inplace=True)
```

In [ ]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 41188 entries, 0 to 41187
Data columns (total 18 columns):
 #   Column         Non-Null Count  Dtype  
---  ------         --------------  -----  
 0   age            41188 non-null  int64  
 1   job            41188 non-null  object 
 2   marital        41188 non-null  object 
 3   education      41188 non-null  object 
 4   default        41188 non-null  object 
 5   housing        41188 non-null  object 
 6   loan           41188 non-null  object 
 7   contact        41188 non-null  object 
 8   month          41188 non-null  object 
 9   day_of_week    41188 non-null  object 
 10  duration       41188 non-null  int64  
 11  campaign       41188 non-null  int64  
 12  pdays          41188 non-null  int64  
 13  previous       41188 non-null  int64  
 14  poutcome       41188 non-null  object 
 15  emp.var.rate   41188 non-null  float64
 16  cons.conf.idx  41188 non-null  float64
 17  y              41188 non-null  object 
dtypes: float64(2), int64(5), object(11)
memory usage: 5.7+ MB
```

In [ ]:
```
# Reportes por grupos
# Cantidad de registros por categoría de variables categóricas
fig, ax = plt.subplots(nrows=3, ncols=4, figsize=(18,16))

categorical_columns = []

for column in df.columns:
    if df[column].dtype == 'object':
        categorical_columns.append(column)

for i, column in enumerate(categorical_columns):
    sns.barplot(data=df.groupby(column).count().reset_index().rename(columns={'age': 'count'}), x='count', y=column,a
```

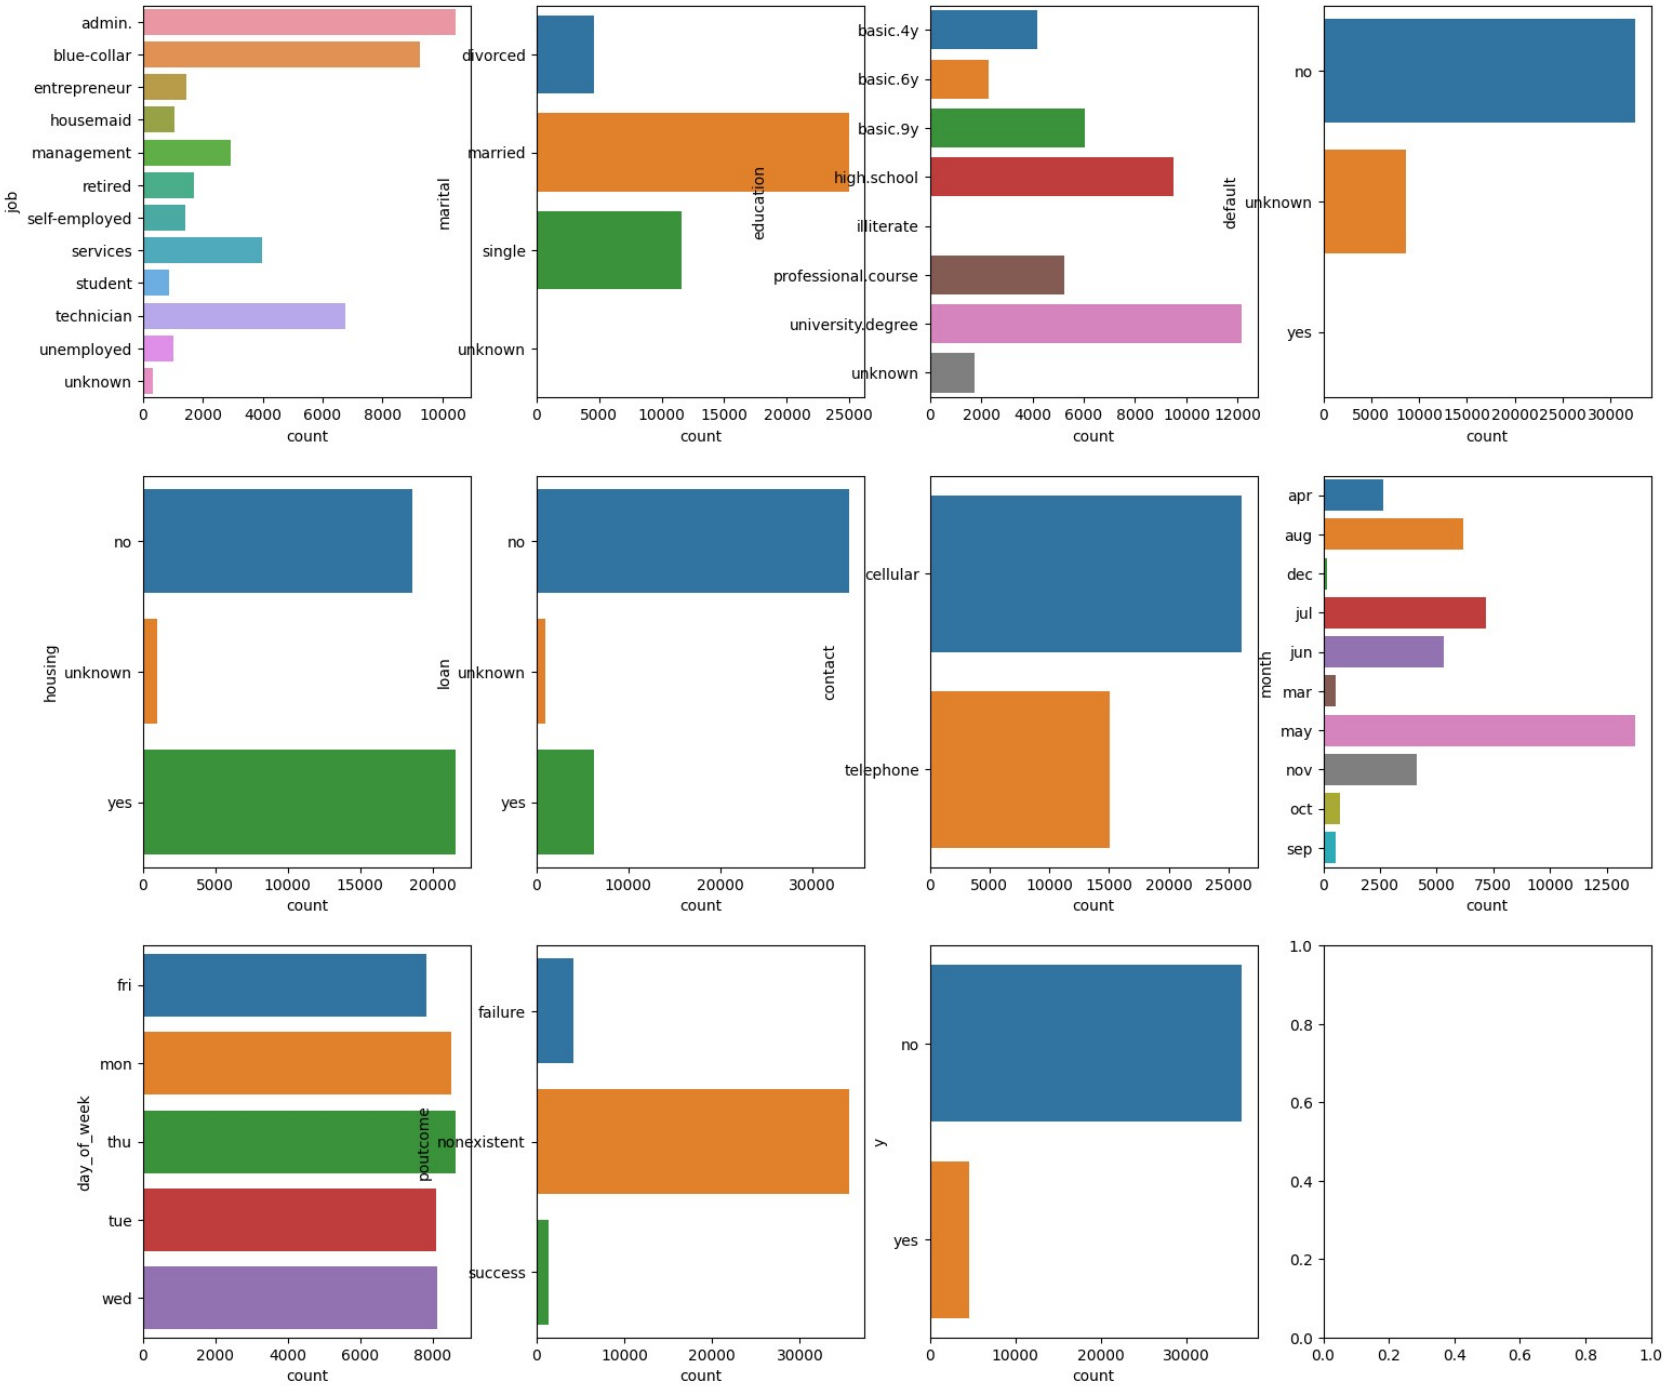
job
admin.
blue-collar
entrepreneur
housemaid
management
retired
self-employed
services
student
technician
unemployed
unknown
count
marital
divorced
married
single
unknown
count
education
basic.4y
basic.6y
basic.9y
high.school
illiterate
professional.course
university.degree
unknown
count
default
no
unknown
yes
count
housing
no
unknown
yes
count
loan
no
unknown
yes
count
contact
cellular
telephone
count
month
apr
aug
dec
jul
jun
mar
may
nov
oct
sep
count
day_of_week
fri
mon
thu
tue
wed
count
poutcome
failure
nonexistent
success
count
y
no
yes
count

In [ ]:
```
# Análisis univariado y bivariado basado en la predicción y/n
# El análisis univariado ya se hizo mediante los histogramas y gráficos de barras antes presentados
# Lo único que no se puede ver es el histograma de la variable pdays una vez que se quitan los registros de personas
fig = sns.histplot(data=df[df['pdays'] < 999]['pdays'])
fig.plot()
```

Out[ ]: []

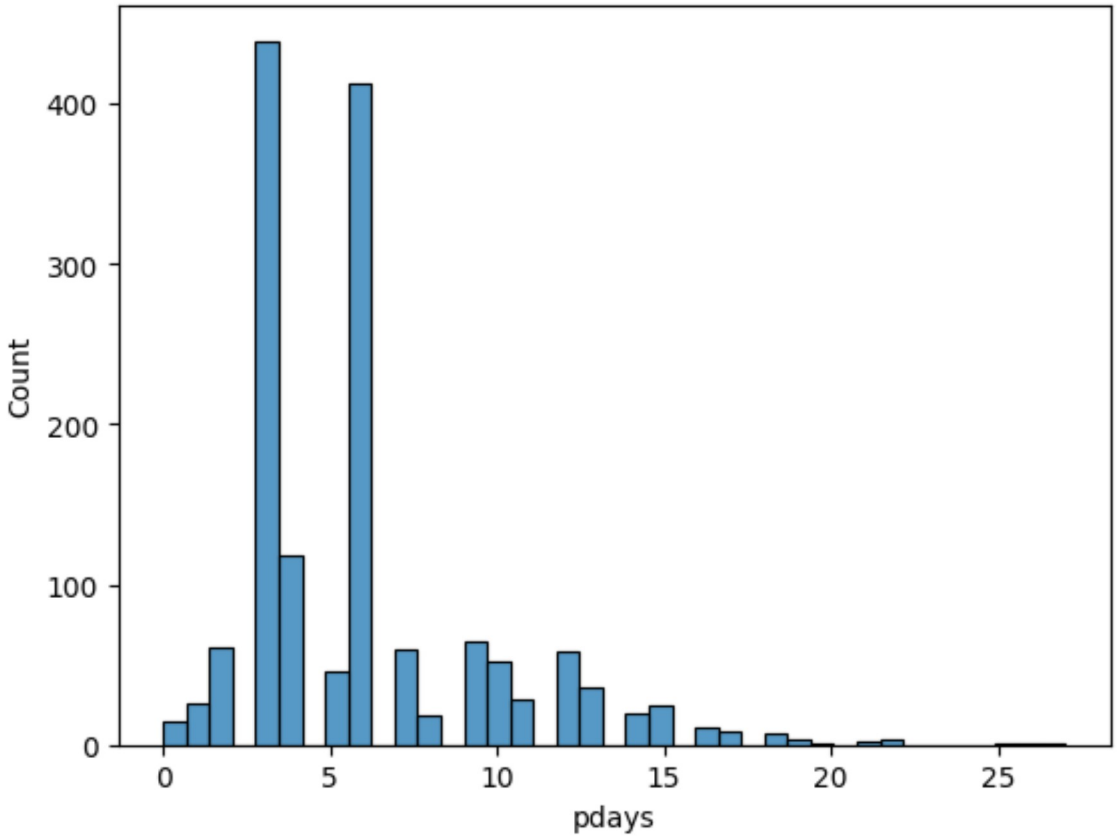

In [ ]:
```
# Análisis bivariado basado en la variable de predicción "y"

fig, ax = plt.subplots(nrows=3, ncols=4, figsize=(40,30))

categorical_columns = []

for column in df.columns:
    if df[column].dtype == 'object':
        categorical_columns.append(column)

for i, column in enumerate(categorical_columns):
    if column != 'y':
        sns.barplot(data=df.groupby([column, 'y']).count().reset_index().rename(columns={'age': 'count'}), x='count',
```

job
admin.
blue-collar
entrepreneur
housemaid
management
retired
self-employed
services
student
technician
unemployed
unknown
count
y
no
yes
marital
divorced
married
single
unknown
education
basic.4y
basic.6y
basic.9y
high.school
illiterate
professional.course
university.degree
unknown
default
no
unknown
yes
housing
loan
contact
cellular
telephone
month
apr
aug
dec
jul
jun
mar
may
nov
oct
sep
day_of_week
fri
mon
thu
tue
wed
poutcome
failure
nonexistent
success

In [ ]:
```
# Análisis univariable utilizando porcentajes

fig, ax = plt.subplots(nrows=3, ncols=4, figsize=(40,30))

for i, column in enumerate(categorical_columns):
    if column != 'y':
        groupby_df = df.groupby([column, 'y']).count().reset_index().rename(columns={'age': 'count'})

        sns.barplot(data=groupby_df.pivot_table(values='count', aggfunc='sum', index='y', columns=column).apply(lambd
```

job
housemaid
services
admin.
blue-collar
technician
retired
management
unemployed
self-employed
unknown
entrepreneur
student
marital
married
single
divorced
unknown
education
basic.4y
high.school
basic.6y
basic.9y
professional.course
unknown
university.degree
illiterate
default
no
unknown
yes
housing
no
yes
unknown
loan
no
yes
unknown
contact
telephone
cellular
month
may
jun
jul
aug
oct
nov
dec
mar
apr
sep
day_of_week
mon
tue
wed
thu
fri
poutcome
nonexistent
failure
success
y
no
yes
value

Insights:

- Se pueden ver que para algunas variables, el success rate (variable y=yes) es significativamente más alto cuando el registro pertenece a un valor específico de esa variable
- Lo que se esperaría de estas últimas gráficas es que, si la variable categorica no tiene efecto sobre el resultado en la variable "y", todas las barras del mismo color sean del mismo tamaño o de un tamaño muy similar entre sí
- Hay categorías de las variables que no tienen un efecto sobre la variable de respuesta "y" como todas las categorías de la variable "day_of_week", todas las categorías de "loan", todas las categorías de "housing", todas las categorías de la variable "marital"
- También hay ciertas categorías de ciertas variables que podrían tener un efecto en la variable de respuesta. Por ejemplo, los clientes con trabajo de estudiante o que estaban retirados fueron con los que más éxito hubo en la campaña del banco. De la misma manera, hubo más éxito en la respuesta para esta campaña con clientes que fueron contactados y con los que se tuvo éxito en campañas pasadas

In [ ]:
```
# Dividir dataset en 70% 30%

df2= df

# Transformar variables numéricas con álto sesgo
numeric_columns = ['age', 'duration', 'campaign', 'pdays', 'previous', 'emp.var.rate', 'cons.conf.idx']
for column in numeric_columns:
    df['log_'+column] = np.log(df[column] + 1)

# Cambiar variable de respuesta por 1 y 0
df['y'] = df['y'].apply(func= lambda x : 1 if x == 'yes' else 0)

# Generar variables categóricas
pd.get_dummies(data=df, drop_first=True)

# Dividir Dataset
from sklearn.model_selection import train_test_split

x = df.drop(columns=['y'])
y = df['y']

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=.30, random_state=1)
```

```
d:\Programas\Python311\Lib\site-packages\pandas\core\arraylike.py:402: RuntimeWarning: invalid value encountered in
log
  result = getattr(ufunc, method)(*inputs, **kwargs)
d:\Programas\Python311\Lib\site-packages\pandas\core\arraylike.py:402: RuntimeWarning: invalid value encountered in
log
  result = getattr(ufunc, method)(*inputs, **kwargs)
```

In [ ]:
```
print("Original Personal Loan True Values   : {0} ({1:0.2f}%)".format(len(df2.loc[df2['y'] == 1]), (len(df2.loc[df2['
print("Original Personal Loan False Values  : {0} ({1:0.2f}%)\n".format(len(df2.loc[df2['y'] == 0]), (len(df2.loc[df2

print("Training Personal Loan True Values   : {0} ({1:0.2f}%)".format(len(y_train.loc[y_train[:] == 1]), (len(y_trair
print("Training Personal Loan False Values  : {0} ({1:0.2f}%)".format(len(y_train.loc[y_train[:] == 0]), (len(y_trair
print('The Training dataset contains {0:0.2f}% of the registers in the original dataset\n'.format( len(y_train[:]) /

print("Testing Personal Loan True Values   : {0} ({1:0.2f}%)".format(len(y_test.loc[y_test[:] == 1]), (len(y_test.loc
print("Testing Personal Loan False Values  : {0} ({1:0.2f}%)".format(len(y_test.loc[y_test[:] == 0]), (len(y_test.loc
print('The Testing dataset contains {0:0.2f}% of the registers in the original dataset\n'.format( len(y_test[:]) / le
```

```
Original Personal Loan True Values   : 4640 (11.27%)
Original Personal Loan False Values  : 36548 (88.73%)

Training Personal Loan True Values   : 3227 (11.19%)
Training Personal Loan False Values  : 25604 (88.81%)
The Training dataset contains 70.00% of the registers in the original dataset

Testing Personal Loan True Values   : 1413 (11.43%)
Testing Personal Loan False Values  : 10944 (88.57%)
The Testing dataset contains 30.00% of the registers in the original dataset
```