Actividad Módulo 31: Ejercicio Series de Tiempo 2

- Importación de datos de Stocks del ejercicio anterior
- Generación de modelo de series de tiempo aplicado a los datos importados usando el modelo de Reversión a la Media y el de Movimiento Browniano
- Modelo autorregresivo y de moving average
- Ejercicio de predicción de modelos
- Visualización simpole de series de Tiempo

In [ ]:
```
# Importar librerias
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sn
```

In [ ]:
```
# Librerías para uso estadístico
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import math
from sklearn.metrics import mean_squared_error
from statsmodels.tsa.arima.model import ARIMA
```

In [ ]:
```
# Se importa el archivo con datos
import os
os.chdir('D:/Documentos/Documentos/DataAnalysis/ebac/Python/Modulo30/')

df_google = pd.read_csv('GOOG.csv', parse_dates=['Date'], index_col='Date')
df_google
```

Out[ ]:

	Open	High	Low	Close	Adj Close	Volume
Date						
2006-01-03	10.523555	10.851077	10.416457	10.840119	10.840119	526815259
2006-01-04	11.056059	11.182087	10.952697	11.089434	11.089434	613747887
2006-01-05	11.108363	11.246595	10.996283	11.238874	11.238874	433952486
2006-01-06	11.379098	11.718576	11.288687	11.598028	11.598028	712938289
2006-01-09	11.616708	11.790805	11.480468	11.628912	11.628912	513593887
...	...	...	...	...	...	...
2017-12-22	53.055500	53.209999	52.972000	53.006001	53.006001	15102000
2017-12-26	52.903500	53.006001	52.509998	52.837002	52.837002	15212000
2017-12-27	52.869499	52.918499	52.402500	52.468498	52.468498	25438000
2017-12-28	52.580002	52.737499	52.238499	52.407001	52.407001	16742000
2017-12-29	52.335999	52.485001	52.244999	52.320000	52.320000	17750000

3020 rows × 6 columns

Serie Geometric Brownian Motion

- Serie aleatoria utilizada para predecir precios de stocks y movimientos tipo random walk
- https://scipy-cookbook.readthedocs.io/items/BrownianMotion.html

In [ ]:

```
from scipy.stats import norm
import pandas as pd

# Parámetros del proceso
delta = 0.25
dt = 0.1

#Punto inicio
x = 0.0
xini = 0

# Número de iteraciones
n = 10

# Genera los distintos puntos de la serie
for k in range(n):
    x = x + norm.rvs(scale=delta**2*dt)
    print(x)
```

```
0.009151291978585035
0.005376296660625556
-0.0029245218717074443
-0.008970285305108478
-0.020575537394574878
-0.01948631039274255
-0.014413414380650387
-0.008901278508771704
-0.007974266132845237
-0.0017580066988555857
```

In [ ]:
```
# Número de trayectorias
ntra = 10

# Número de iteraciones
n = 20

# Se pueden guardar los caminos diferenes en un dataframe
res = []
dfres = pd.DataFrame().assign(traj=0, nsample=0, sample=0)
dfres
```

Out[ ]:

traj	nsample	sample

In [ ]:
```
# Genera las trayectorias en un dataframe (dfres)
for i in range(ntra+1):
    for k in range(1,n+1):
        x = x + norm.rvs(scale=delta**2*dt)
        res.append(x)
        df2 = {'traj': i, 'nsample':k, 'sample':x}
        dfres = pd.concat(objs=[dfres, pd.DataFrame(df2, index=[0])], axis=0, ignor
        # dfres = dfres.append(df2, ignore_index=True)


# Genera los puntos iniciales en 0
for i in range(ntra+1):
    df2 = {'traj': i, 'nsample':0, 'sample': xini}
    dfres = pd.concat(objs=[dfres, pd.DataFrame(df2, index=[0])], ignore_index=True
    # dfres = dfres.append(df2, ignore_index=True)
dfres
```

Out[ ]:

	traj	nsample	sample
0	0	1	-0.001503
1	0	2	-0.009927
2	0	3	-0.015357
3	0	4	-0.015476
4	0	5	-0.014999
...	...	...	...
226	6	0	0.000000
227	7	0	0.000000
228	8	0	0.000000
229	9	0	0.000000
230	10	0	0.000000

231 rows × 3 columns

In [ ]:

```
import seaborn as sns
sns.lineplot(data=dfres, x='nsample', y='sample', legend=None, ci=None, hue='traj')
```

```
C:\Users\USER\AppData\Local\Temp\ipykernel_10444\1469885987.py:2: FutureWarning:

The `ci` parameter is deprecated. Use `errorbar=None` for the same effect.

  sns.lineplot(data=dfres, x='nsample', y='sample', legend=None, ci=None, hue='traj
')
```

Out[ ]:

```
<AxesSubplot: xlabel='nsample', ylabel='sample'>
```

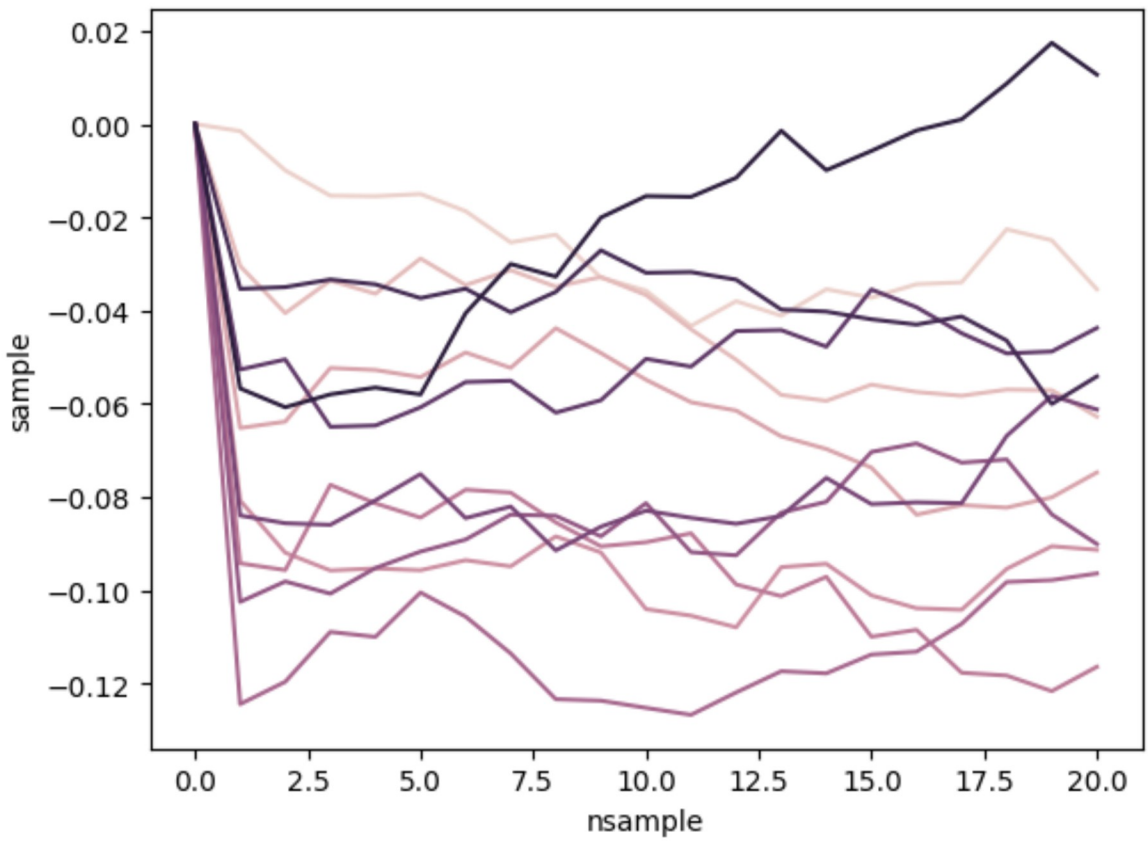

Serie Reversión a la Media

- Conocido como el modelo Vasicek
- Muy utilizado para predecir tasas de Bancos Centrales, niveles de actividad económicos

In [ ]:
```
def mod_vasicek(r0, K, theta, sigma, T=1, N=10, seed=777):
    np.random.seed(seed)
    dt = T/float(N)
    rates = [r0]
    for i in range(N):
        dr = K*(theta-rates[-1])*dt + sigma*np.random.normal()
        rates.append(rates[-1]+dr)
    return range(N+1), rates
```

In [ ]:
```
# Parámetros para la serie de tiempo
r0 = 0.1875             # Punto inicial
K = 0.2                 # Velocidad de reversión a la media
theta = 0.04            # Nivel de largo plazo de la variable
sigma = 0.012
T = 10
seed = np.random.randint(100,900)
N = 1000

# Llama a la función Vasicek
x, y = mod_vasicek(r0, K, theta, sigma, T, N, seed)
```

In [ ]:
```
# Generación de gráfica del modelo de Reversión a la Media
plt.plot(x,y)
plt.title('Gráfico de Modelo de Reversión a la Media')
plt.axhline(theta, color='red')
plt.show()
```

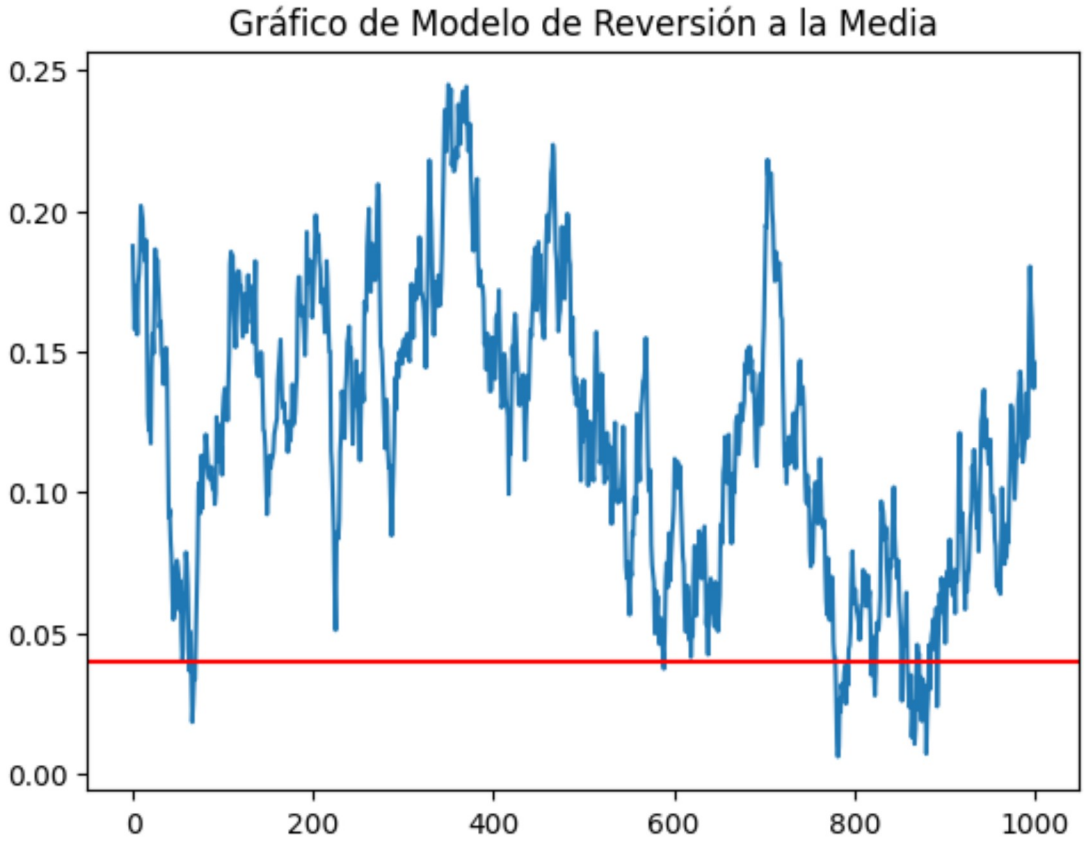

Serie de Tiempo Autorregresiva (AR)

In [ ]:
```
# Predicción de Precio de Google
google_price = ARIMA(df_google['Close'].diff().iloc[1:].values, order=(1,0,0))
res = google_price.fit()
plt.plot(res.predict())
plt.plot(df_google['Close'].diff().iloc[1:].values, alpha=.5)
plt.legend(['Prediction', 'Real'])
plt.title('Predicción vs Real - Diferencia entre el cierre de un día y el cierre de
```

```
d:\Programas\Python311\Lib\site-packages\statsmodels\base\model.py:607: Convergence
Warning: Maximum Likelihood optimization failed to converge. Check mle_retvals
  warnings.warn("Maximum Likelihood optimization failed to "
```

Out[ ]:
```
Text(0.5, 1.0, 'Predicción vs Real - Diferencia entre el cierre de un día y el cier
re del día anterior')
```

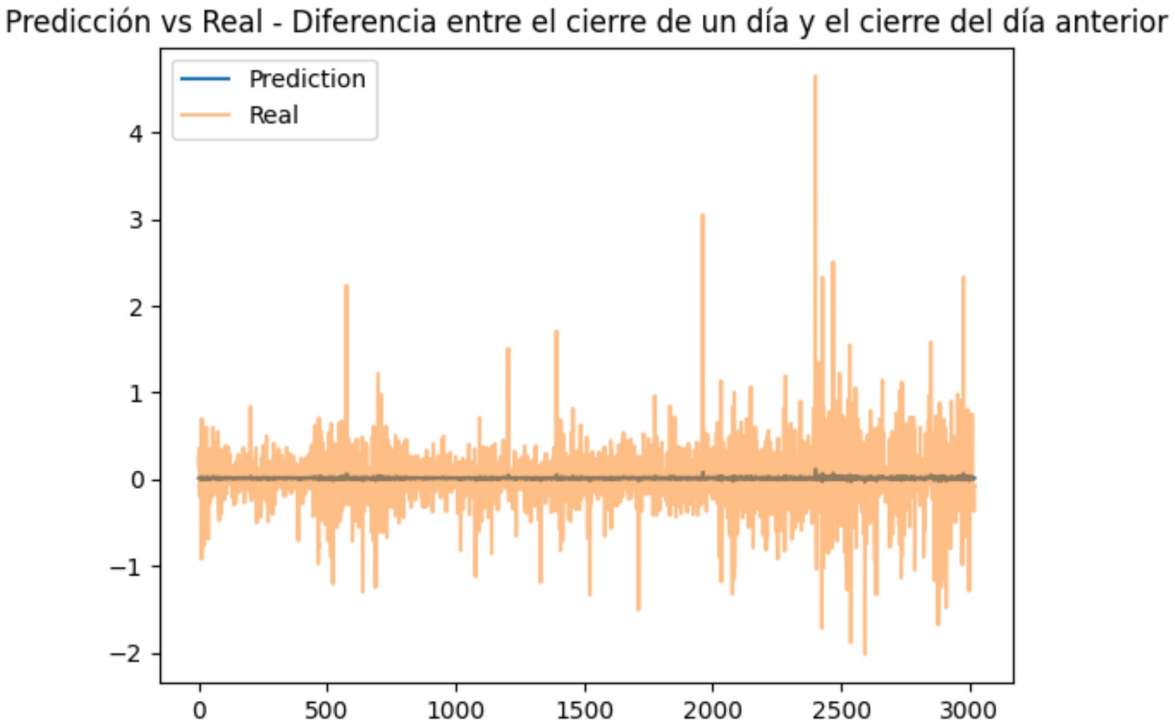

In [ ]:
```
rmse = math.sqrt(mean_squared_error(df_google['High'].diff().iloc[900:1000].values,
print(f'RMSE = {rmse}')
```

```
RMSE = 0.13272682167412392
```

In [ ]:
```
res.summary()
```

Out[ ]:

SARIMAX Results

Dep. Variable:	y	**No. Observations:**	3019
Model:	ARIMA(1, 0, 0)	**Log Likelihood**	-1039.887
Date:	Fri, 13 Oct 2023	**AIC**	2085.773
Time:	20:08:16	**BIC**	2103.811
Sample:	0	**HQIC**	2092.259
	- 3019		
Covariance Type:	opg		

	coef	**std err**	**z**	**P>|z|**	**[0.025**	**0.975]**
const	0.0137	0.007	2.092	0.036	0.001	0.027
ar.L1	0.0220	0.013	1.698	0.089	-0.003	0.047
sigma2	0.1166	0.001	115.621	0.000	0.115	0.119

Ljung-Box (L1) (Q):	0.00	**Jarque-Bera (JB):**	43854.65
Prob(Q):	0.99	**Prob(JB):**	0.00
Heteroskedasticity (H):	3.28	**Skew:**	1.14
Prob(H) (two-sided):	0.00	**Kurtosis:**	21.53

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Moving Averages Series

- Las series de tipo MA tienen una aproximación para modelar series de tiempo univariadas
- El modelo de promedios móviles especifica que la salida depende linearmente de la predicción de los términos de error y además un término estocástico no calculable

In [ ]:
```
# Predicciones para el precio de Google
# Lo que se va a predecir son las variaciones absolutas

# Se define la serie ARMA y luego se procede con el model fit
# Order tiene los parámetros p,(d) y q de AR y MA respectivamente
model = ARIMA(df_google['Close'].diff().iloc[1:].values, order=(0,0,5))
result = model.fit()
```

In [ ]:
```
print(f'μ={result.params[0]:.6} ,  θ={result.params[1]:.6}')
print(result.summary())
```

```
μ=0.0137341 ,  θ=0.0208895
                                 SARIMAX Results
==============================================================================
Dep. Variable:                      y   No. Observations:                 3019
Model:                 ARIMA(0, 0, 5)   Log Likelihood               -1037.477
Date:                Fri, 13 Oct 2023   AIC                           2088.954
Time:                        20:08:17   BIC                           2131.043
Sample:                             0   HQIC                          2104.089
                               - 3019
Covariance Type:                  opg
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const          0.0137      0.006      2.218      0.027       0.002       0.026
ma.L1          0.0209      0.013      1.564      0.118      -0.005       0.047
ma.L2          0.0070      0.015      0.468      0.640      -0.022       0.036
ma.L3         -0.0326      0.013     -2.464      0.014      -0.058      -0.007
ma.L4         -0.0205      0.012     -1.674      0.094      -0.044       0.004
ma.L5         -0.0152      0.013     -1.137      0.256      -0.041       0.011
sigma2         0.1164      0.001    112.649      0.000       0.114       0.118
===================================================================================
Ljung-Box (L1) (Q):                   0.00   Jarque-Bera (JB):             45616.59
Prob(Q):                              0.99   Prob(JB):                         0.00
Heteroskedasticity (H):               3.26   Skew:                             1.16
Prob(H) (two-sided):                  0.00   Kurtosis:                        21.90
===================================================================================

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-ste
p).
```

In [ ]:
```
rmse = math.sqrt(mean_squared_error(df_google['Close'].diff().iloc[900:1000].values
print(f'RMSE = {rmse}')
```

```
RMSE = 0.1408360549581567
```

In [ ]:
```
plt.plot(result.predict())
plt.plot(df_google['Close'].diff().iloc[1:].values, alpha=.5)
plt.legend(['Prediction', 'Real'])
plt.title('Predicción vs Real - Diferencia entre el cierre de un día y el cierre de
```

Out[ ]:
```
Text(0.5, 1.0, 'Predicción vs Real - Diferencia entre el cierre de un día y el cier
re del día anterior')
```

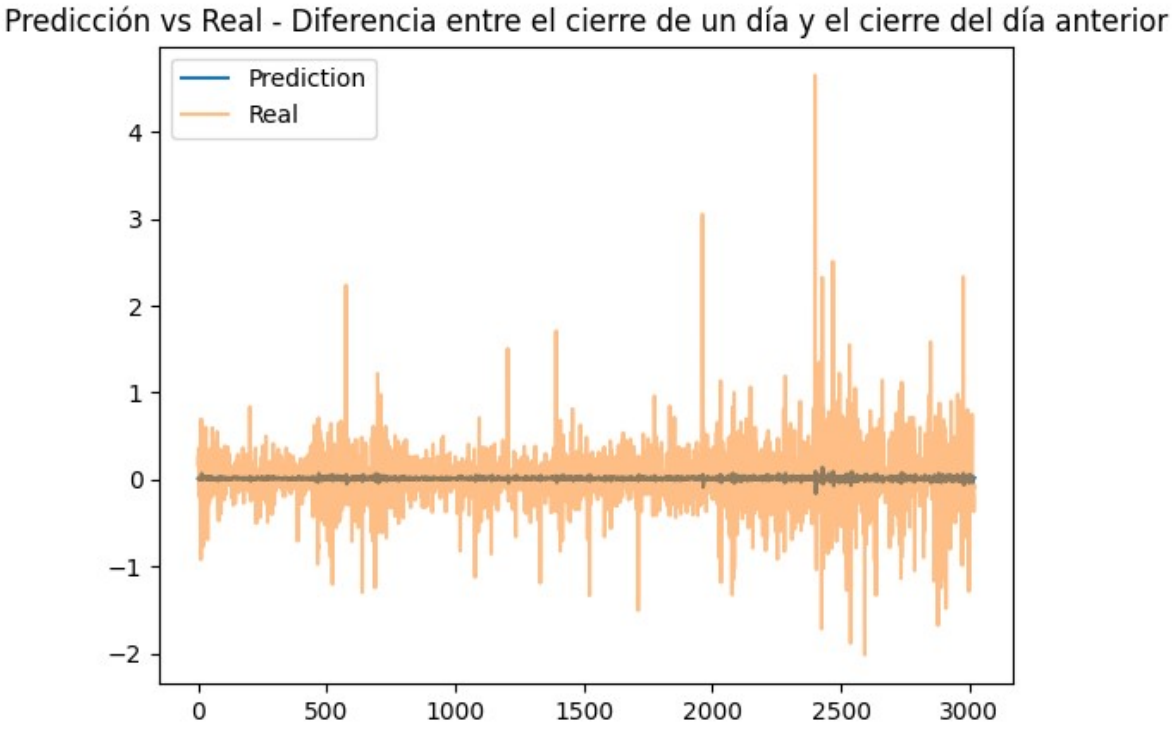
Predicción vs Real - Diferencia entre el cierre de un día y el cierre del día anterior
Prediction
Real
4
3
2
1
0
−1
−2
0
500
1000
1500
2000
2500
3000