# Actividad Módulo 27: Introducción a Regresión

1. Importación de un modelo con datos de ventas de casas (housing.csv)
2. EDA Completo siguiendo los modelos anteriores
3. Feature engineering - estandarización, eliminación y creación de nuevas columnas
4. Generación de variables dummy en el set de datos
5. Aplicación del modelo de regresión lineal a la variable Price
6. Entrenamiento y evaluación del modelo
7. Análisis de sensibilidad e importancia de variables
8. Visualización de los resultados del modelo de regresión
9. Matriz de confusión y medidas del modelo
10. Conclusiones

In [ ]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

In [ ]:
```
df = pd.read_csv('Housing.csv')
df.sample(5)
```

Out[ ]:

| | price | area | bedrooms | bathrooms | stories | mainroad | guestroom | basement | hotwaterhea |
|---|---|---|---|---|---|---|---|---|---|
| **263** | 4410000 | 3968 | 3 | 1 | 2 | no | no | no | |
| **35** | 8080940 | 7000 | 3 | 2 | 4 | yes | no | no | |
| **519** | 2450000 | 4840 | 2 | 1 | 2 | yes | no | no | |
| **298** | 4200000 | 5800 | 3 | 1 | 1 | yes | no | no | |
| **42** | 7700000 | 6480 | 3 | 2 | 4 | yes | no | no | |

# Exploratory Data Analysis

- Propiedades generales del df - shape, info, cantidad de nulos
- Análisis univariado - Histogramas de cada columna
- Análisis Bivariado - Matriz de correlación, crosstabs

In [ ]:
```
# Tamaño del dataframe
df.shape
```

Out[ ]: (545, 13)

In [ ]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 545 entries, 0 to 544
Data columns (total 13 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   price             545 non-null    int64
 1   area              545 non-null    int64
 2   bedrooms          545 non-null    int64
 3   bathrooms         545 non-null    int64
 4   stories           545 non-null    int64
 5   mainroad          545 non-null    object
 6   guestroom         545 non-null    object
 7   basement          545 non-null    object
 8   hotwaterheating   545 non-null    object
 9   airconditioning   545 non-null    object
 10  parking           545 non-null    int64
 11  prefarea          545 non-null    object
 12  furnishingstatus  545 non-null    object
dtypes: int64(6), object(7)
memory usage: 55.5+ KB
```

In [ ]:
```python
# Describe
df.describe().T
```

Out[ ]:

| | count | mean | std | min | 25% | 50% | 75% | |
|---|---|---|---|---|---|---|---|---|
| **price** | 545.0 | 4.766729e+06 | 1.870440e+06 | 1750000.0 | 3430000.0 | 4340000.0 | 5740000.0 | 13300( |
| **area** | 545.0 | 5.150541e+03 | 2.170141e+03 | 1650.0 | 3600.0 | 4600.0 | 6360.0 | 16: |
| **bedrooms** | 545.0 | 2.965138e+00 | 7.380639e-01 | 1.0 | 2.0 | 3.0 | 3.0 | |
| **bathrooms** | 545.0 | 1.286239e+00 | 5.024696e-01 | 1.0 | 1.0 | 1.0 | 2.0 | |
| **stories** | 545.0 | 1.805505e+00 | 8.674925e-01 | 1.0 | 1.0 | 2.0 | 2.0 | |
| **parking** | 545.0 | 6.935780e-01 | 8.615858e-01 | 0.0 | 0.0 | 0.0 | 1.0 | |

In [ ]:
```python
# Determinar si será necesaria la imputación de datos
print('Cantidad de datos faltantes por columna')
df.isnull().sum()

# La imputación de datos no será necesaria
```

```
Cantidad de datos faltantes por columna
```

Out[ ]:
```
price               0
area                0
bedrooms            0
bathrooms           0
stories             0
mainroad            0
guestroom           0
basement            0
hotwaterheating     0
airconditioning     0
parking             0
prefarea            0
furnishingstatus    0
dtype: int64
```

In [ ]:
```
# Análisis univariado - distribuciones de las variables

fig, ax = plt.subplots(nrows=4, ncols=4, figsize=(20,20))

for i, col in enumerate(df.columns):
    sns.histplot(data=df, x=col, ax=ax[i//4, i%4])
```

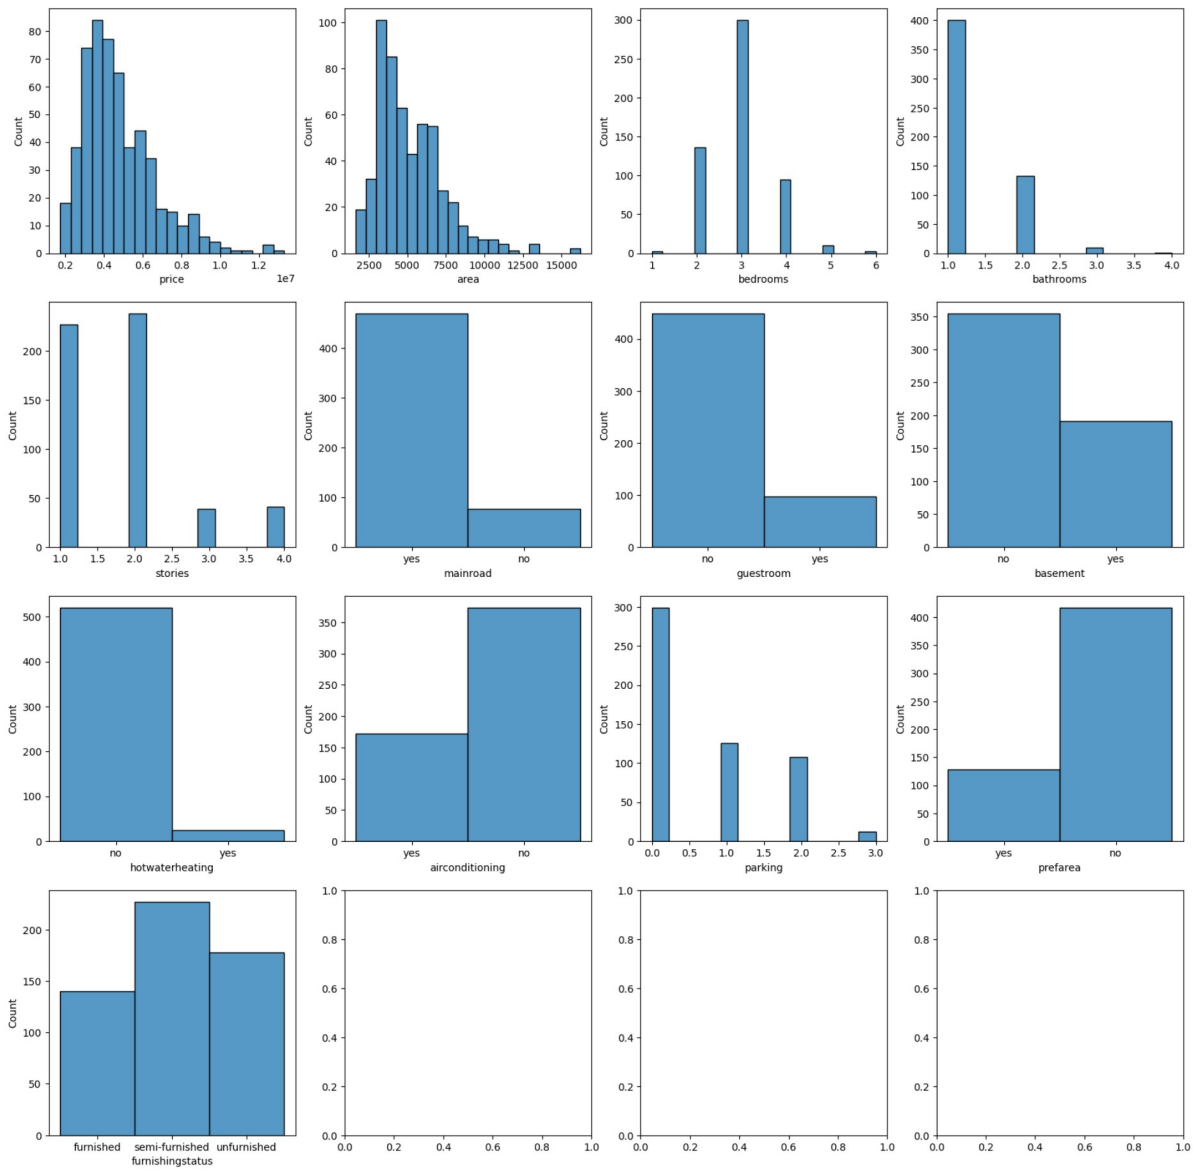


In [ ]:
```
# Matriz de correlación
corr = df.corr(method='pearson')
plt.figure(figsize=(8,6))
df_lt = corr.where(np.tril(np.ones(corr.shape)).astype(bool))
hmap  = sns.heatmap(data=df_lt, annot=True, cmap='YlGnBu', fmt='.2f')
```

```
C:\Users\USER\AppData\Local\Temp\ipykernel_9844\516176349.py:2: FutureWarning: The
default value of numeric_only in DataFrame.corr is deprecated. In a future version,
it will default to False. Select only valid columns or specify the value of numeric
_only to silence this warning.
  corr = df.corr(method='pearson')
```

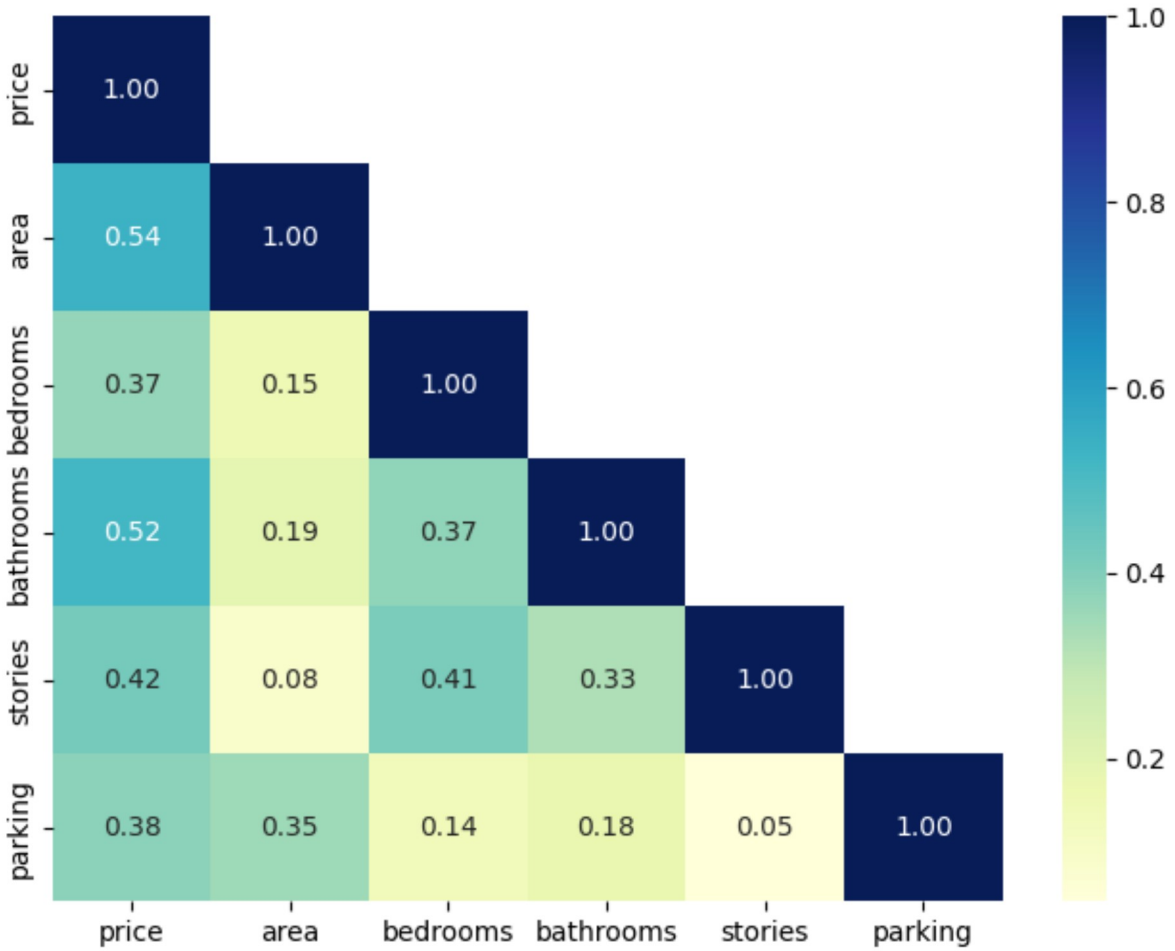


In [ ]:
```
# Crosstabs
pd.crosstab(index=df['bedrooms'], columns=df['stories'], normalize='index').plot.ba
```

Out[ ]: <AxesSubplot: ylabel='bedrooms'>

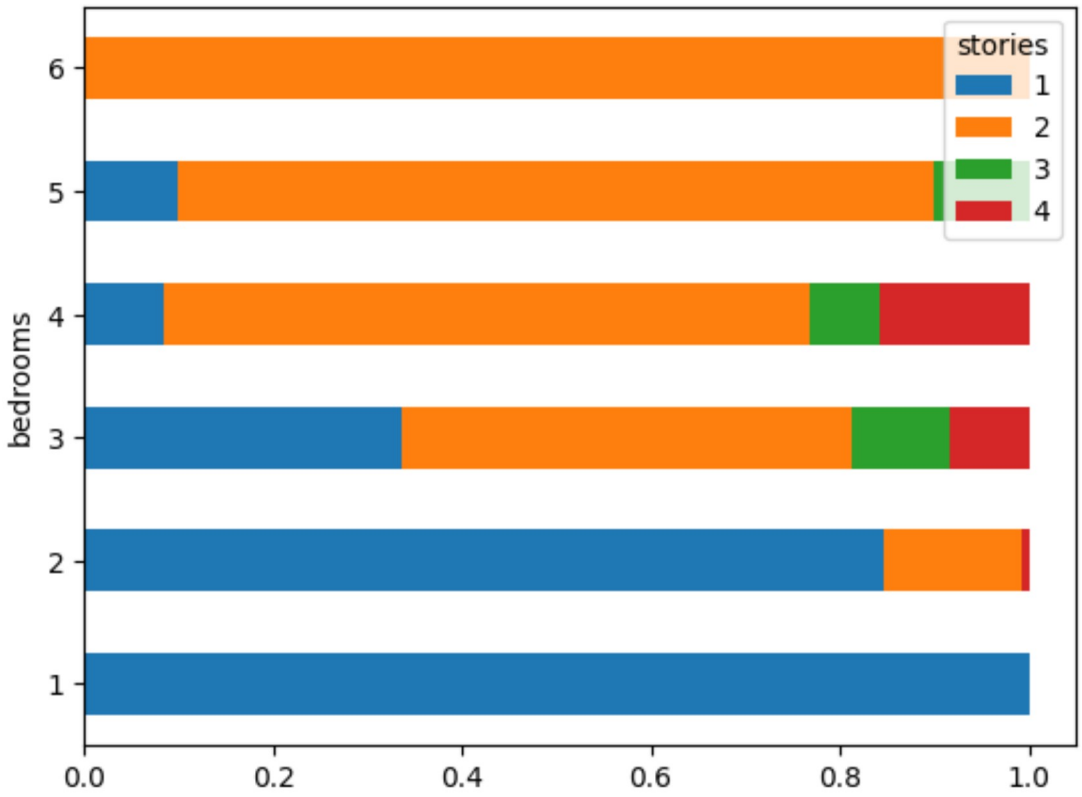


In [ ]:
```
pd.crosstab(index=df['stories'], columns=df['guestroom'], normalize='index').plot.b
```

Out[ ]: <AxesSubplot: ylabel='stories'>

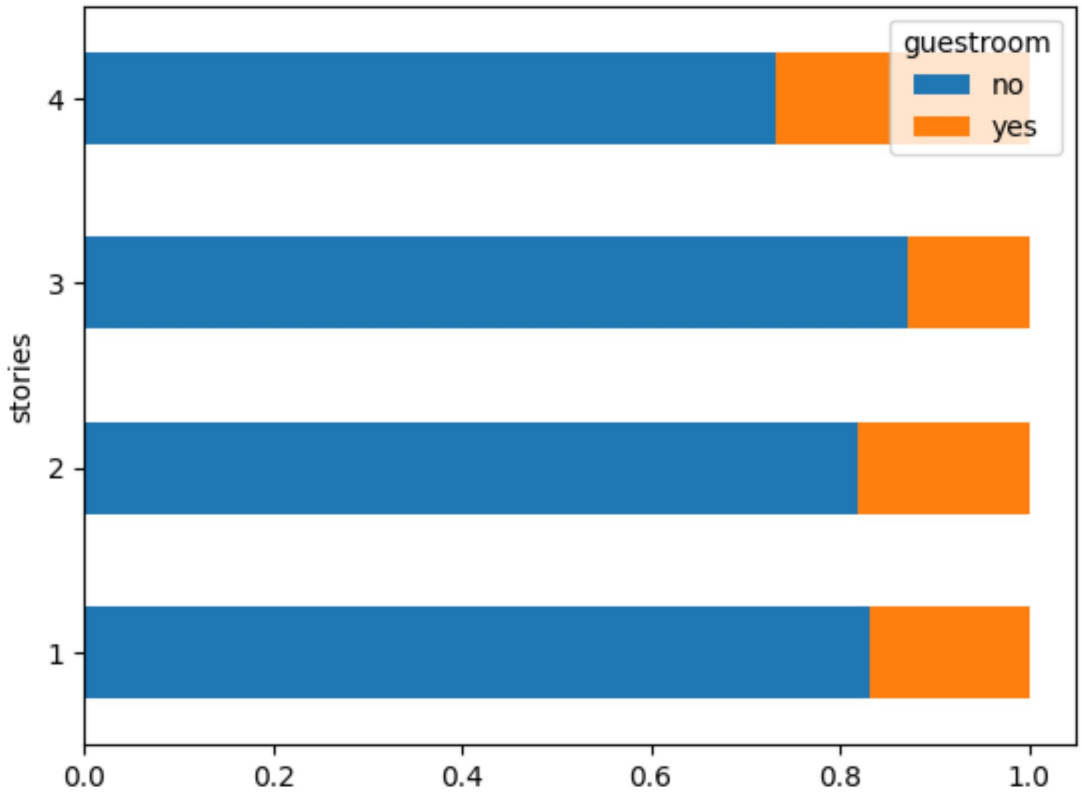


In [ ]:
```
pd.crosstab(index=df['parking'], columns=df['prefarea'], normalize='index').plot.ba
```

Out[ ]: <AxesSubplot: ylabel='parking'>

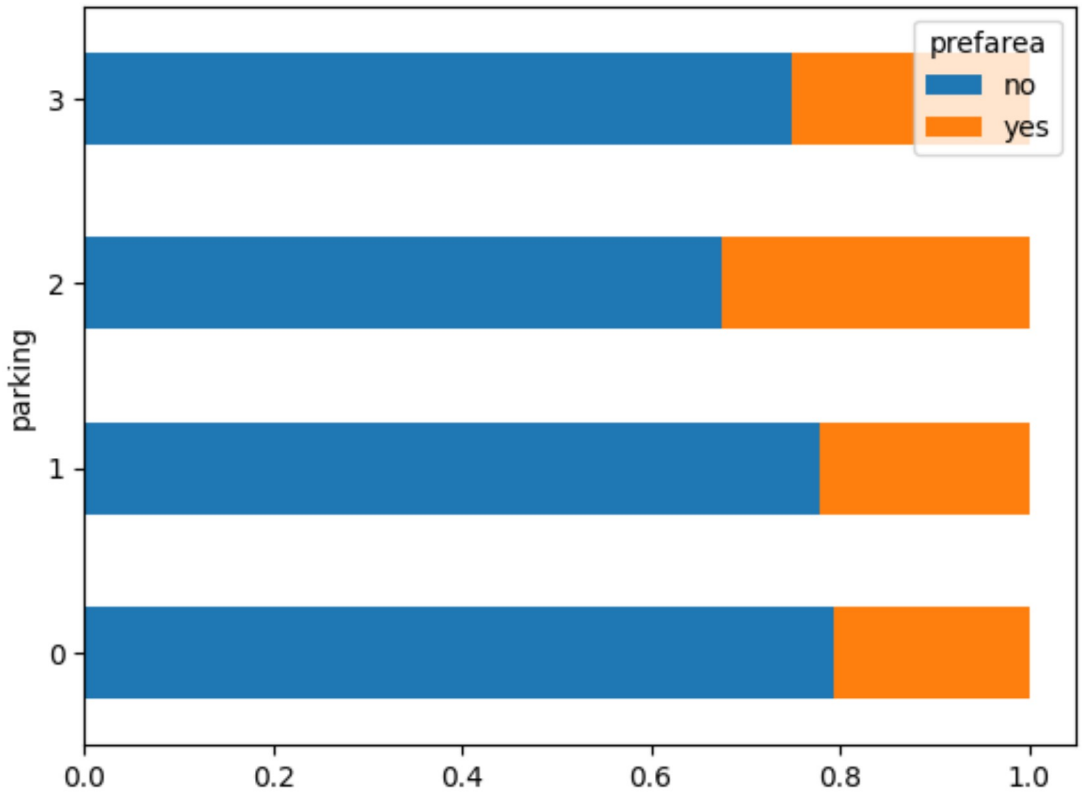


In [ ]:
```
pd.crosstab(index=df['furnishingstatus'], columns=df['prefarea'], normalize='index'
```

Out[ ]: <AxesSubplot: ylabel='furnishingstatus'>

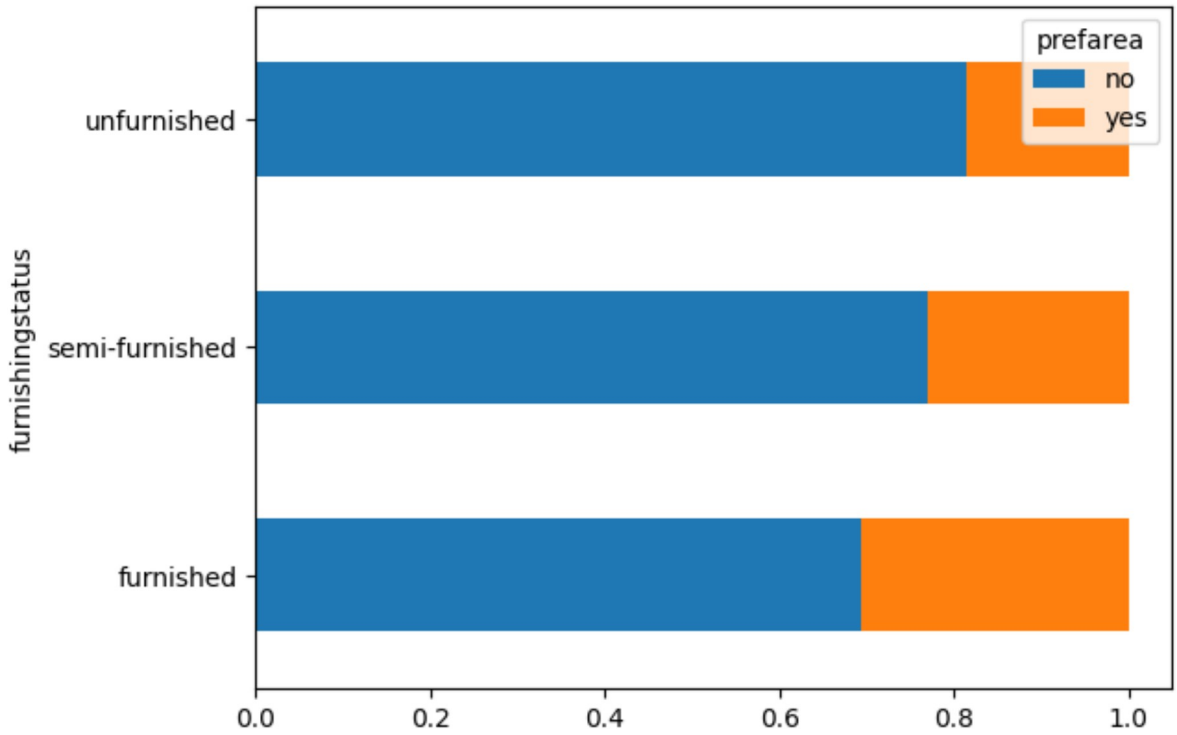


In [ ]:
```
# Violin Charts
sns.violinplot(data=df, x='stories', y='price')
```

Out[ ]: <AxesSubplot: xlabel='stories', ylabel='price'>

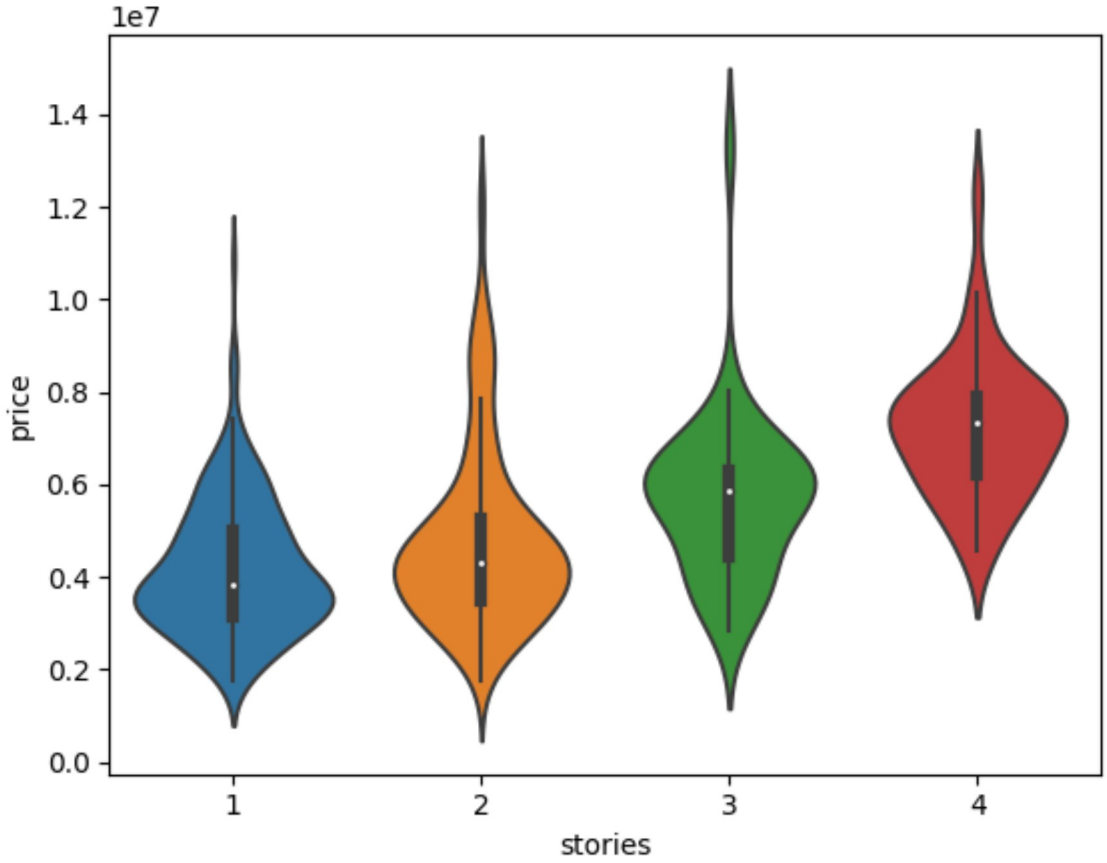


In [ ]:
```
sns.violinplot(data=df, x='prefarea', y='price')
```

Out[ ]: <AxesSubplot: xlabel='prefarea', ylabel='price'>

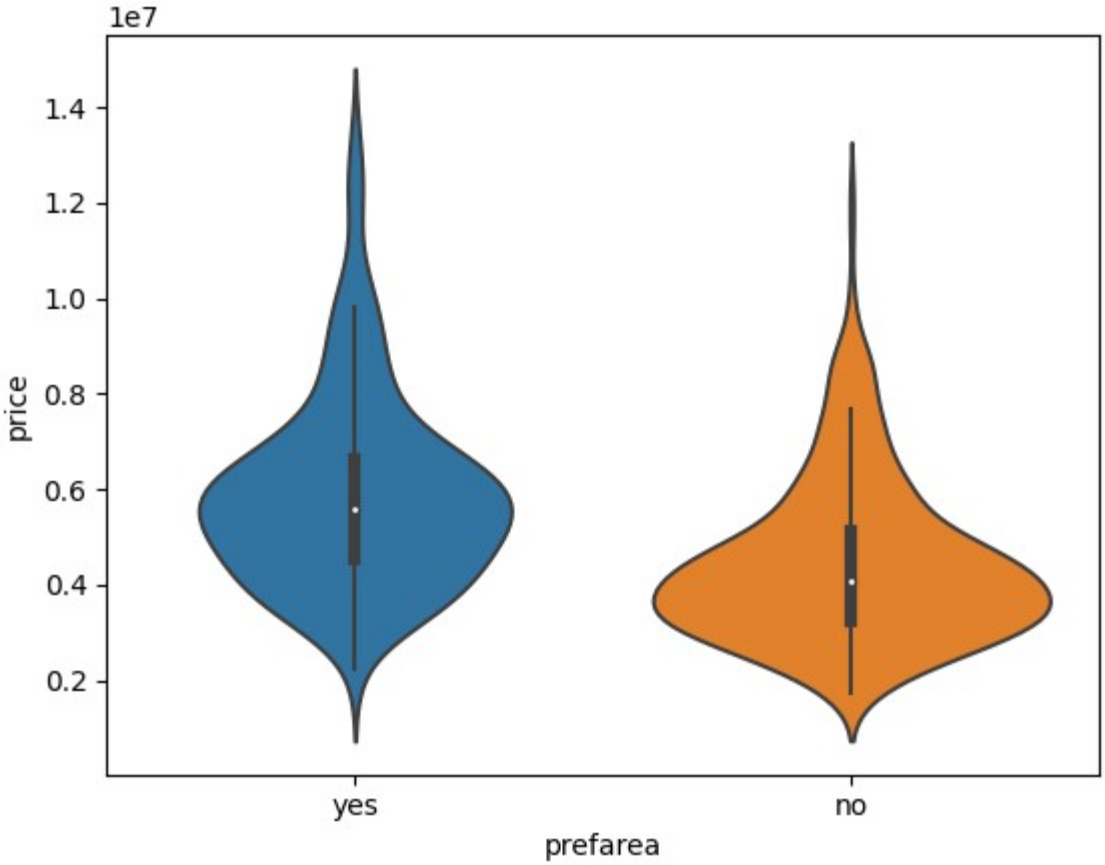
1e7
1.4
1.2
1.0
0.8
0.6
0.4
0.2
price
yes
no
prefarea

In [ ]:
```
sns.violinplot(data=df, x='prefarea', y='area')
```

Out[ ]: <AxesSubplot: xlabel='prefarea', ylabel='area'>

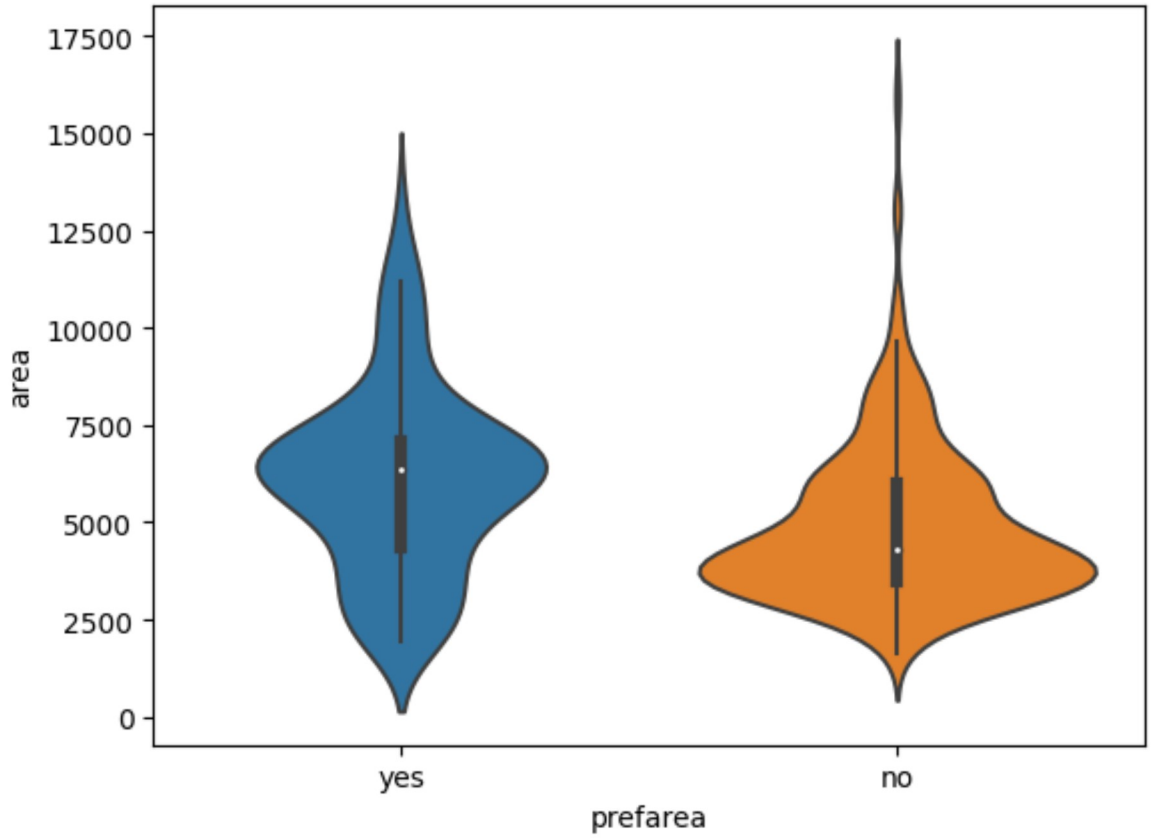


In [ ]:
```
sns.violinplot(data=df, x='furnishingstatus', y='price')
```

Out[ ]: <AxesSubplot: xlabel='furnishingstatus', ylabel='price'>

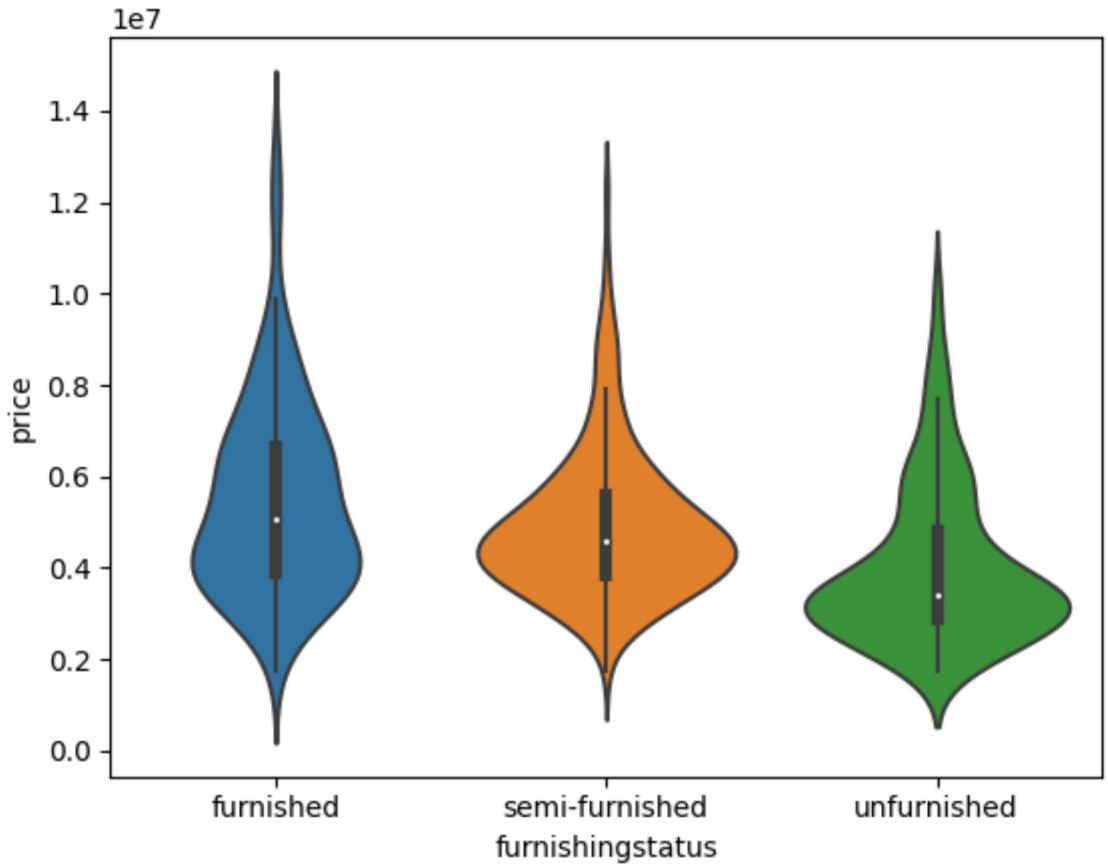


In [ ]:
```
# Revisar si hay clases subrepresentadas, especialmente para variables con multiple
pd.crosstab(index=df['bedrooms'], columns='col', normalize=True)
```

Out[ ]:

| col_0 | col |
|---|---|
| **bedrooms** | |
| **1** | 0.003670 |
| **2** | 0.249541 |
| **3** | 0.550459 |
| **4** | 0.174312 |
| **5** | 0.018349 |
| **6** | 0.003670 |

In [ ]:
```
pd.crosstab(index=df['bathrooms'], columns='col', normalize=True)
```

Out[ ]:

| col_0 | col |
|---|---|
| **bathrooms** | |
| **1** | 0.735780 |
| **2** | 0.244037 |
| **3** | 0.018349 |
| **4** | 0.001835 |

In [ ]:
```
pd.crosstab(index=df['stories'], columns='col', normalize=True)
```

Out[ ]:

| col_0 | col |
|---|---|
| **stories** | |
| **1** | 0.416514 |
| **2** | 0.436697 |
| **3** | 0.071560 |
| **4** | 0.075229 |

In [ ]:
```
pd.crosstab(index=df['hotwaterheating'], columns='col', normalize=True)
```

Out[ ]:

| col_0 | col |
|---|---|
| **hotwaterheating** | |
| **no** | 0.954128 |
| **yes** | 0.045872 |

In [ ]:
```
pd.crosstab(index=df['parking'], columns='col', normalize=True)
```

Out[ ]:

| col_0 | col |
|---|---|
| **parking** | |
| **0** | 0.548624 |
| **1** | 0.231193 |
| **2** | 0.198165 |
| **3** | 0.022018 |

## EDA Insights

- No hay datos faltantes en el dataset, no será necesaria la imputación de datos
- No existe alta correlación entre ningún par de variables, por lo que no será necesario quitar una variable por posible multicolinealidad
- Tanto el área como el precio son variables con sesgo, se necesitarán transformar con logarítmo natural
- Existen clases desbalanceadas dentro de las variables categóricas bedrooms, bathrooms, parking (categorías que se encuentran presentes en menos del 5% de los registros del dataset)
- Hay variables categóricas que se pueden pasar directamente a 1/0, otras se pueden pasar a numéricos 1,2,3... o se pueden hacer variables dummies

---

# Feature Engineering

- Transformación de columnas con sesgo si es necesario
- Estandarización de columnas con escalas diferentes al resto
- Transformación de columnas con variables categóricas a 1/0

In [ ]:
```
# Crear copia del df antes de alterarlo
df2 = df.copy()

# No se transformarán las columnas con sesgo para no alterar la moderada correlació
```

In [ ]:
```
# Transformar variables categóricas yes/no en 1/0
df2['mainroad'] = df2.mainroad.replace(to_replace={'yes':1, 'no':0})
df2['guestroom'] = df2.guestroom.replace(to_replace={'yes':1, 'no':0})
df2['basement'] = df2.basement.replace(to_replace={'yes':1, 'no':0})
df2['airconditioning'] = df2.airconditioning.replace(to_replace={'yes':1, 'no':0})
df2['prefarea'] = df2.prefarea.replace(to_replace={'yes':1, 'no':0})
df2['hotwaterheating'] = df2.hotwaterheating.replace(to_replace={'yes':1, 'no':0})


df2.sample(5)
```

Out[ ]:

| | price | area | bedrooms | bathrooms | stories | mainroad | guestroom | basement | hotwaterhea |
|---|---|---|---|---|---|---|---|---|---|
| **215** | 4830000 | 4160 | 3 | 1 | 3 | 1 | 0 | 0 | |
| **448** | 3150000 | 4095 | 2 | 1 | 1 | 1 | 0 | 0 | |
| **279** | 4270000 | 6360 | 2 | 1 | 1 | 1 | 0 | 0 | |
| **67** | 6895000 | 7700 | 3 | 2 | 1 | 1 | 0 | 0 | |
| **527** | 2275000 | 1836 | 2 | 1 | 1 | 0 | 0 | 1 | |

In [ ]:
```
# Generación de variables dummy (para furnishing status)
df2 = pd.get_dummies(df2)
```

# Modelo de regresión lineal

In [ ]:
```
# Aplicación de un modelo de regresión lineal
x = df2.drop(columns=['price'])
y = df2.price

# División del dataset en training y testing - 70% training, 30% testing
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=.3)
```

In [ ]:
```
# Ejecutar modelo de regresion lineal
from sklearn.linear_model import LinearRegression

regression_model = LinearRegression()

# Entrenamiento del modelo
regression_model.fit(X=x_train, y=y_train)
```

Out[ ]:
```
▾ LinearRegression
LinearRegression()
```

In [ ]:
```
# Evaluación del modelo de regresión
from sklearn.metrics import mean_absolute_error, r2_score, mean_squared_error, mean

y_predict = regression_model.predict(X=x_test)

print('Score: ', regression_model.score(X=x_test, y=y_test))
print(f'R2: {r2_score(y_true=y_test, y_pred=y_predict):.2f}')
print(f'Mean absolute error: {mean_absolute_error(y_true=y_test, y_pred=y_predict):
print(f'Mean squared error: {mean_squared_error(y_true=y_test, y_pred=y_predict):.2
print(f'Mean absolute percentage error: {mean_absolute_percentage_error(y_true=y_te
```

```
Score:  0.6551538994436636
R2: 0.66
Mean absolute error: 776617.87
Mean squared error: 983053988613.61
Mean absolute percentage error: 18.72%
```

In [ ]:
```
# Revisión de los residuales entre la predicccción del modelo y el valor real
plt.hist(x=y_predict-y_test, bins=20)
plt.title('Residuales (prediction-real)')
```

Out[ ]:
```
Text(0.5, 1.0, 'Residuales (prediction-real)')
```

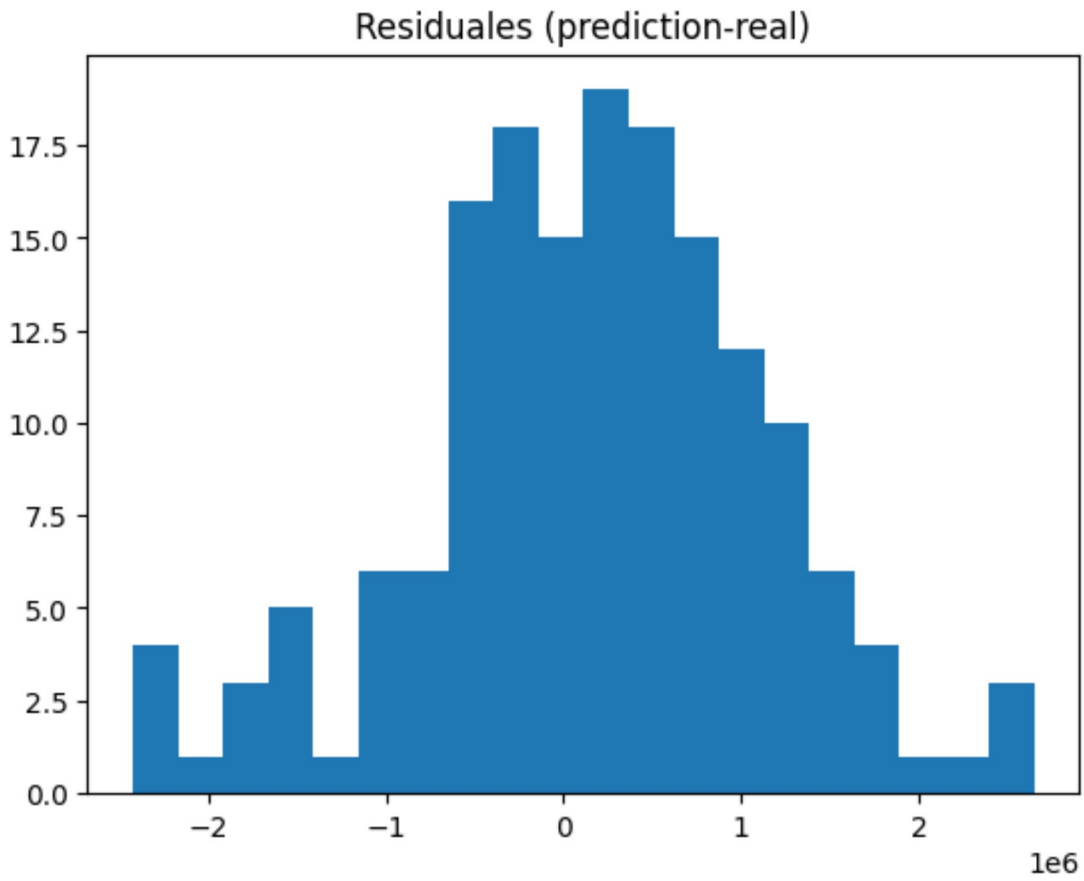


In [ ]:
```
# Probar la normalidad de los residuales del modelo
from scipy.stats import shapiro     # Shapiro-Wilkinson Normality Test

stat, p = shapiro(x=y_predict-y_test)
print('stat=%.3f, p=%.3f\n' % (stat,p))

if p > .05:
    print('Probably Gaussian (Normally distributed)')
else:
    print('Probably not Gaussian')
```

```
stat=0.987, p=0.129

Probably Gaussian (Normally distributed)
```

## Insights:

- El modelo entrenado puede explicar el 64% de las observaciones de testing, con estto se podría esperar que genere predicciones cercanas a la realidad en un 64% de las ocasiones
- El error medio absoluto es de 755k, esto quiere decir que se espera que el error entre la predicción y el valor real de la casa sea de ese valor (puede ser tanto para arriba del precio real, como para abajo), lo cual representa un 17% de diferencia respecto al precio real esperado
- De acuerdo con el test de normalidad de Shapiro-Wilkinson, los residuales siguen una distribución normal

---

# Análisis de sensibilidad e importancia de las variables

- Visualizar e interpretar la ecuación de regresión

In [ ]:
```
regression_model.coef_
```

Out[ ]:
```
array([ 2.85029158e+02,  1.13153075e+05,  1.04151110e+06,  4.57224498e+05,
        3.77914563e+05,  1.92276168e+05,  4.01201148e+05,  5.95015192e+05,
        8.13118787e+05,  2.52507075e+05,  5.86399635e+05,  2.06361637e+05,
        1.13124460e+05, -3.19486096e+05])
```

In [ ]:
```
# Imprimir los coeficientes de las diferentes variables

for idx, col_name in enumerate(x_train.columns):
    print("Coef {} = {:,.2f}".format(col_name, regression_model.coef_[idx]))

print(f'Intercept = {regression_model.intercept_:,.2f}')
```

```
Coef area = 285.03
Coef bedrooms = 113,153.08
Coef bathrooms = 1,041,511.10
Coef stories = 457,224.50
Coef mainroad = 377,914.56
Coef guestroom = 192,276.17
Coef basement = 401,201.15
Coef hotwaterheating = 595,015.19
Coef airconditioning = 813,118.79
Coef parking = 252,507.08
Coef prefarea = 586,399.63
Coef furnishingstatus_furnished = 206,361.64
Coef furnishingstatus_semi-furnished = 113,124.46
Coef furnishingstatus_unfurnished = -319,486.10
Intercept = -246,097.94
```

## Insights

- Dados los coeficientes, se puede concluir:
  - Por cada pie cuadrado de área, se espera pagar $285 más
  - Por cada baño, se espera que el costo de la casa suba en poco más de un millón, siendo la variable con mayor sensibilidad
  - La segunda variable con mayor sensibilidad es el aire acondicionado. Si la unidad posee aire acondicionado, se espera qeu incremente el costo en $813k
  - Cuando la casa viene sin amublar, se puede ver que es 432k más barata que cuando esta semi-amueblada y 525k más barata que cuando se encuentra completamente amueblada
  - Otras variables sensibles:
    - Stories - 457k por cada piso que posee la casa
    - Basement - 401k más si tiene sótano
    - Hot Water - 595k más si tiene calefacción de agua
    - Pref Area - 586k más si se encuentra en área preferencial

---

# Visualización de los resultados del modelo de regresión

In [ ]:
```
predictions = regression_model.predict(x_test)
plt.scatter(y_test, predictions)
plt.title('Comparación de Predicción (x) y Real (y)')
```

Out[ ]:
```
Text(0.5, 1.0, 'Comparación de Predicción (x) y Real (y)')
```

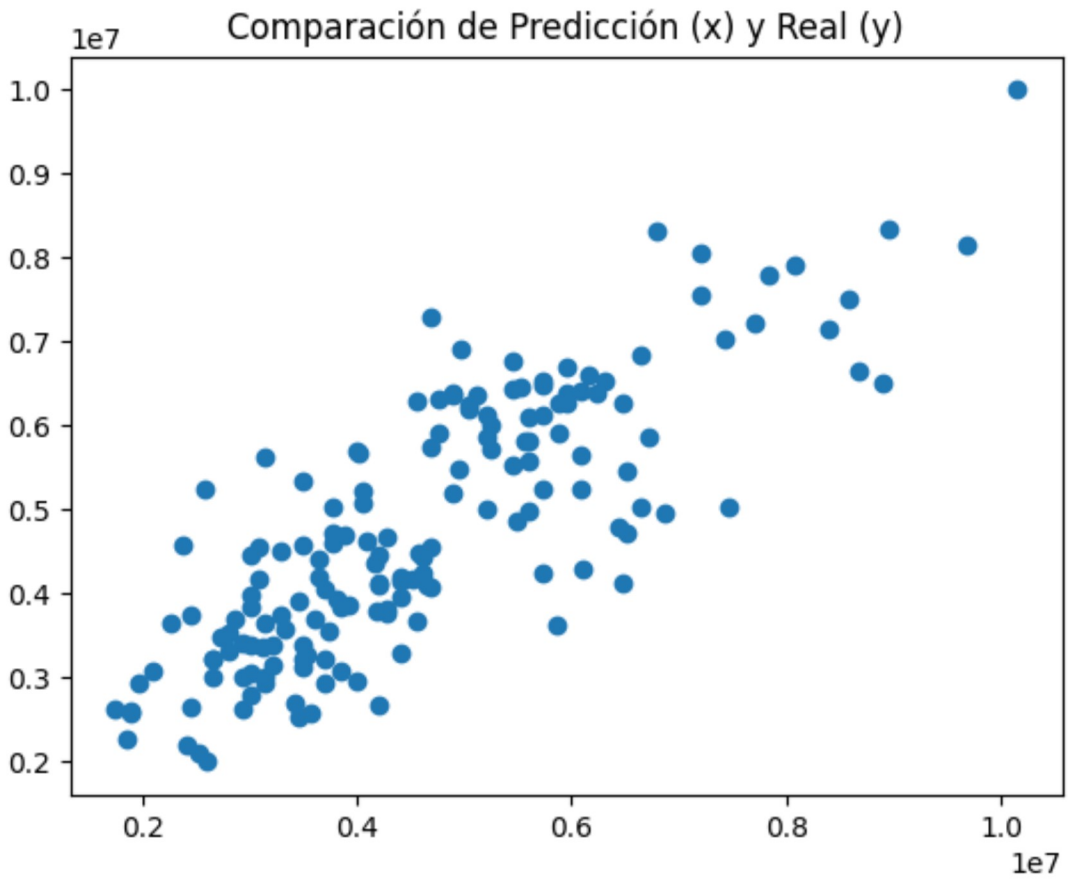


In [ ]:
```
variables = ['area', 'bedrooms', 'stories' ,'parking']
for var in variables:
    plt.figure()
    sns.regplot(x=var, y='price', data=df2).set(title=f'Regresión de {var} y Precio
```

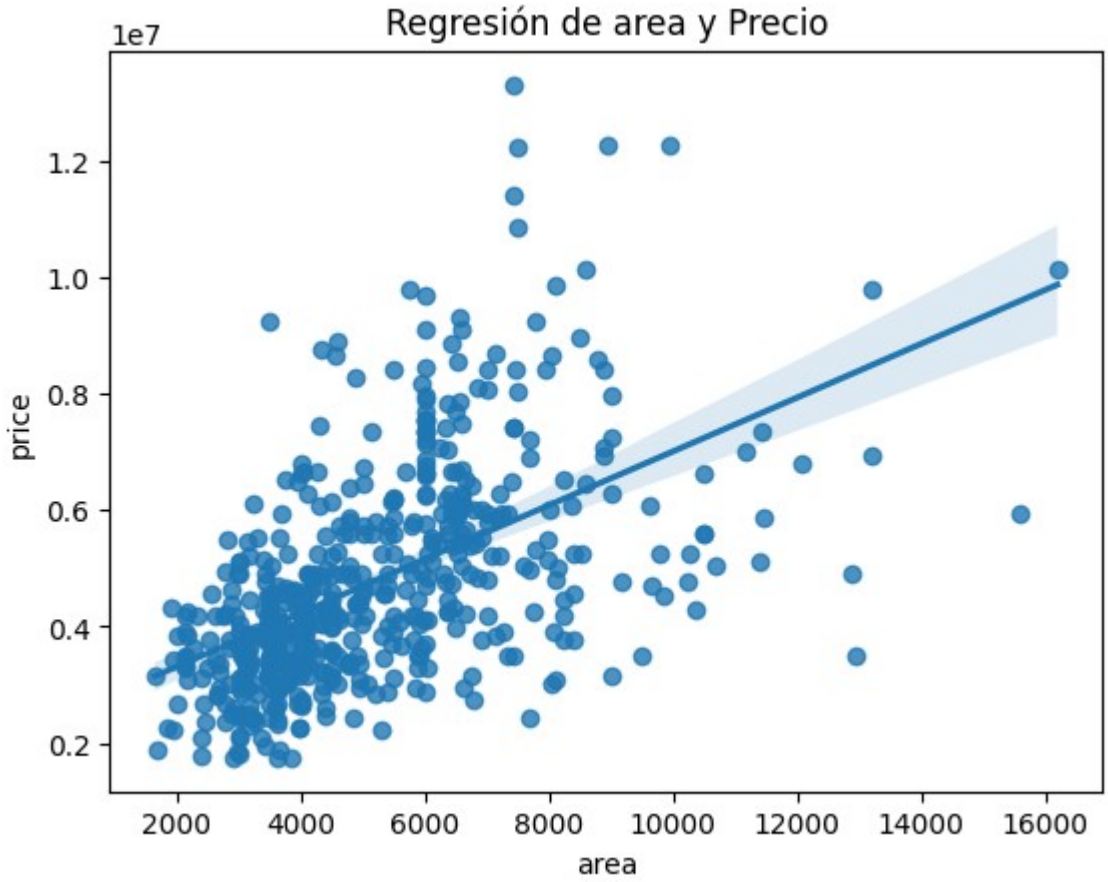
Regresión de area y Precio
1e7
1.2
1.0
0.8
0.6
0.4
0.2
price
2000
4000
6000
8000
10000
12000
14000
16000
area

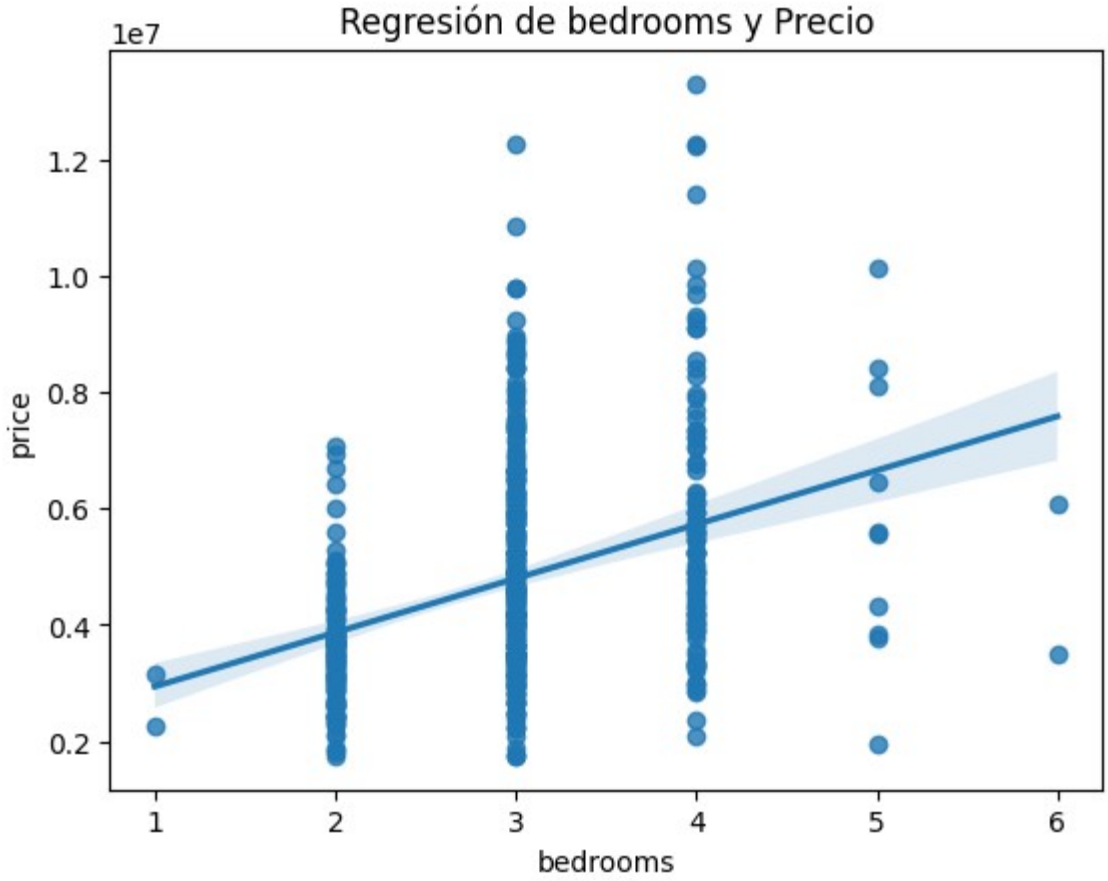
Regresión de bedrooms y Precio
1e7
1.2
1.0
0.8
0.6
0.4
0.2
price
1
2
3
4
5
6
bedrooms

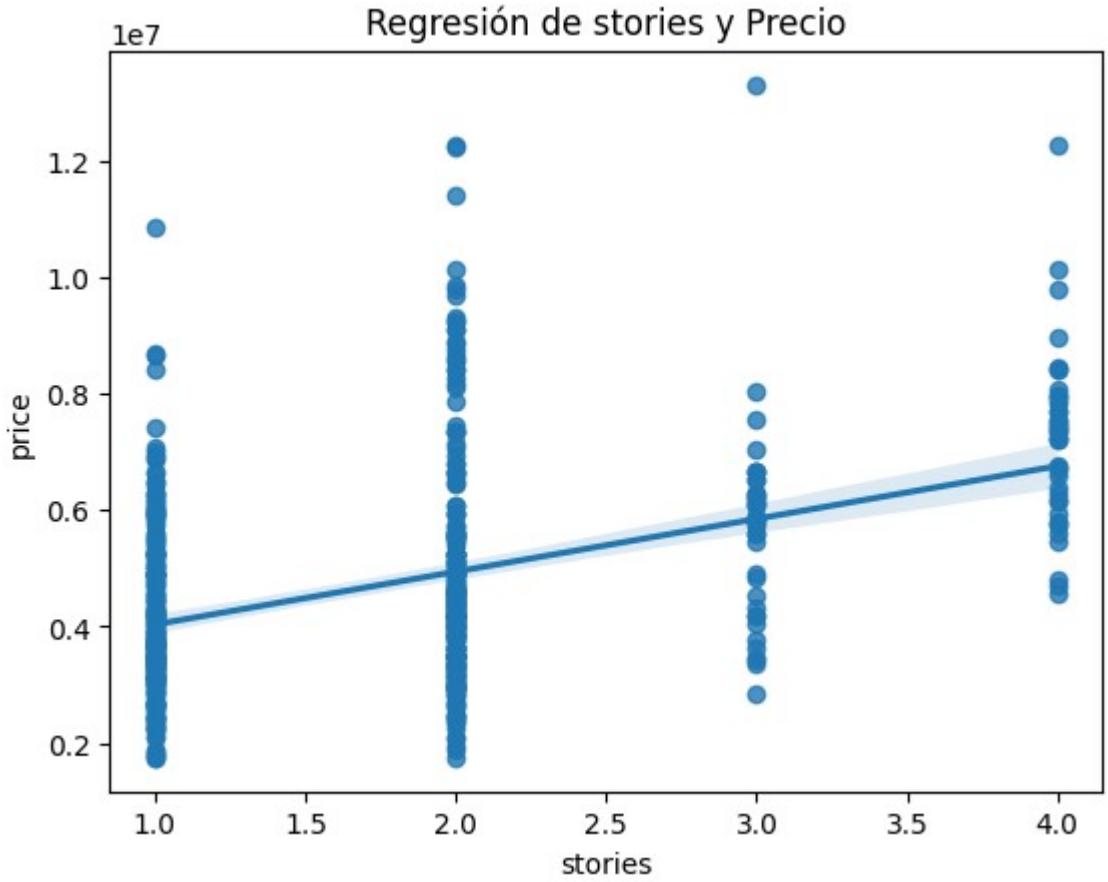
Regresión de stories y Precio
1e7
1.2
1.0
0.8
0.6
0.4
0.2
price
1.0
1.5
2.0
2.5
3.0
3.5
4.0
stories

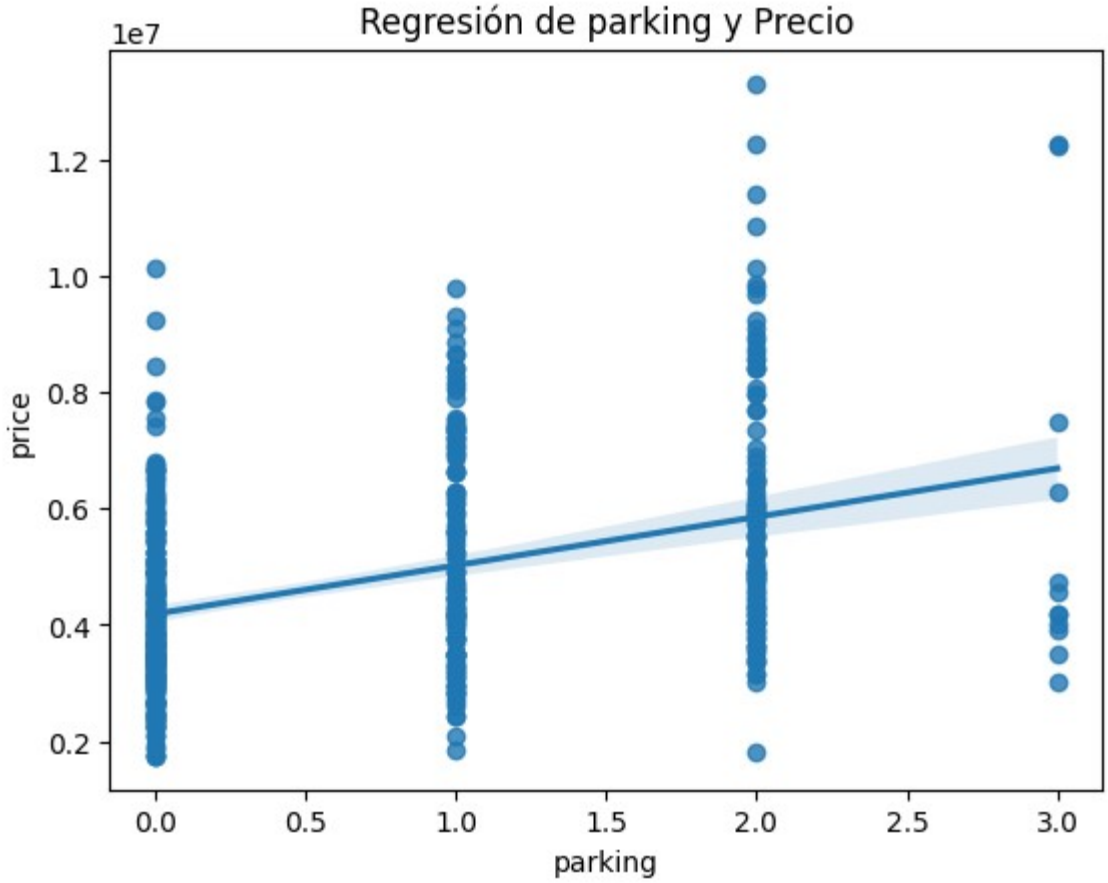
Regresión de parking y Precio
1e7
1.2
1.0
0.8
0.6
0.4
0.2
price
0.0
0.5
1.0
1.5
2.0
2.5
3.0
parking

# Conclusiones

Nota: se dejo fuera la matriz de confusión puesto que no es posible evaluar el desempeño de un modelo de regresión lineal con este método

- El modelo entrenado puede explicar el 64% de las observaciones de testing, con estto se podría esperar que genere predicciones cercanas a la realidad en un 64% de las ocasiones
- El error medio absoluto es de 755k, esto quiere decir que se espera que el error entre la predicción y el valor real de la casa sea de ese valor (puede ser tanto para arriba del precio real, como para abajo), lo cual representa un 17% de diferencia respecto al precio real esperado
- De acuerdo con el test de normalidad de Shapiro-Wilkinson, los residuales siguen una distribución normal
- Existen variables de alta sensibilidad que pueden hacer que el precio de la casa cambie drásticamente como:
  - La cantidad de baños
  - Si está no amueblada, semi-amueblada o totalmente amueblada
  - Si tiene aire acondicionado
  - El número de pisos que tiene la casa
  - Si tiene o no sótano
  - Si tiene calefacción de agua
  - Si está en un área preferencial